Tarea Computacional

Cálculo para Ciencia de Datos · IMT2220

2026-2

Vicente Pardo
Agustín Pérez
Cristóbal Robinson
Sofía Solorza

Profesor: Eduardo Cerpa

1 Pregunta 1

(a) i.

Gradiente de J_0

Utilizaremos la regla de la cadena y el proceso visto en la clase 10, por lo que es necesario descomponer J_0 y definir las funciones

$$p : \mathbb{R}^n \to \mathbb{R}^n, \quad p(x) = Ax - b, \qquad\qquad q : \mathbb{R}^n \to \mathbb{R}, \quad q(u) = \|u\|_2^2,$$

de modo que $J_0(x) = q(p(x))$. Por la regla de la cadena,

$$DJ_0(x) = Dq(p(x))\, Dp(x).$$

Utilizamos los índices $i, j \in \{1, \ldots, n\}$, donde i indica la componente p_i de p, j indica la variable x_j respecto de la cual derivamos. Entonces

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix}, \qquad x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, \qquad b = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix}.$$

Desarrollamos

$$p(x) = Ax - b = \begin{pmatrix} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n - b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n - b_2 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n - b_n \end{pmatrix} = \begin{pmatrix} p_1(x) \\ p_2(x) \\ \vdots \\ p_n(x) \end{pmatrix},$$

que expresado en sumatoria es

$$p_i(x) = \sum_{k=1}^{n} a_{ik}x_k - b_i.$$

Jacobiana de p. Escribimos la suma, tambien escribiendo el término con x_j:

$$p_i(x) = a_{i1}x_1 + \cdots + a_{ij}x_j + \cdots + a_{in}x_n - b_i.$$

Derivando cada término respecto de x_j: si $k \neq j$, el término $a_{ik}x_k$ no depende de x_j y su derivada es 0, si $k = j$, se tiene $\frac{\partial}{\partial x_j}(a_{ij}x_j) = a_{ij}$, y como b_i es constante, su derivada también es 0. Luego

$$\frac{\partial p_i}{\partial x_j}(x) = a_{ij},$$

y reemplazando en la matriz jacobiana,

$$Dp(x) = \begin{pmatrix} \frac{\partial p_1}{\partial x_1} & \cdots & \frac{\partial p_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial p_n}{\partial x_1} & \cdots & \frac{\partial p_n}{\partial x_n} \end{pmatrix} = \begin{pmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{pmatrix} = A.$$

Jacobiana de q. Usando el mismo proceso, escribimos

$$q(u) = \sum_{k=1}^{n} u_k^2 = u_1^2 + \cdots + u_j^2 + \cdots + u_n^2.$$

Derivando respecto de u_j, los términos con $k \neq j$ no dependen de u_j, por lo que solo queda el término con $k = j$:

$$\frac{\partial q}{\partial u_j}(u) = 2u_j, \qquad \text{entonces} \qquad Dq(u) = \begin{pmatrix} 2u_1 & 2u_2 & \cdots & 2u_n \end{pmatrix} = 2u^T.$$

Regla de la cadena. Evaluando Dq en $u = p(x) = Ax - b$,

$$DJ_0(x) = Dq(p(x))\, Dp(x) = 2(Ax-b)^T A.$$

Gradiente. Como $J_0 : \mathbb{R}^n \to \mathbb{R}$ es una función escalar, su jacobiana $DJ_0(x)$ es una matriz fila de tamaño $1 \times n$ cuyas entradas son las derivadas parciales $\frac{\partial J_0}{\partial x_j}$. El gradiente $\nabla J_0(x)$ es el vector columna con esas mismas derivadas, por lo que $\nabla J_0(x) = DJ_0(x)^T$. Usando $(PQ)^T = Q^T P^T$,

$$\nabla J_0(x) = \left[2(Ax-b)^T A\right]^T = 2A^T \left((Ax-b)^T\right)^T = 2A^T(Ax-b).$$

$$\boxed{\nabla J_0(x) = 2A^T(Ax-b)}$$

Hessiana de J_0

La entrada (i,j) de la Hessiana es $\frac{\partial}{\partial x_j}\left(\frac{\partial J_0}{\partial x_i}\right)$. Como $\frac{\partial J_0}{\partial x_i}$ es la componente i de ∇J_0, la Hessiana es la jacobiana del gradiente.

Partimos del gradiente obtenido anteriormente y lo expandimos:

$$\nabla J_0(x) = 2A^T(Ax-b) = 2A^TAx - 2A^Tb.$$

Definimos

$$M = 2A^TA \in M_{n\times n}(\mathbb{R}), \qquad c = 2A^Tb \in \mathbb{R}^n,$$

que no dependen de x. Entonces

$$\nabla J_0(x) = Mx - c,$$

que tiene la misma forma que $p(x) = Ax - b$, con M en vez de A y c en vez de b. Siendo m_{ik} las entradas de M, la componente i del gradiente es

$$(\nabla J_0)_i(x) = \sum_{k=1}^{n} m_{ik}x_k - c_i.$$

Siguiendo el mismo procedimiento que para p, al derivar respecto de x_j solo sobrevive el término con $k = j$, ya que los términos con $k \neq j$ no dependen de x_j y c_i es constante. Por lo tanto

$$\frac{\partial}{\partial x_j}(\nabla J_0)_i(x) = m_{ij}, \qquad \text{y} \qquad \boxed{H_{J_0}(x) = M = 2A^TA.}$$

Además, H_{J_0} no depende de x y es simétrica, ya que $(2A^TA)^T = 2A^T(A^T)^T = 2A^TA$.

Puntos críticos. Un punto x es crítico si $\nabla J_0(x) = 0$:

$$2A^T(Ax-b) = 0 \iff 2A^TAx - 2A^Tb = 0 \iff 2A^TAx = 2A^Tb \iff A^TAx = A^Tb.$$

Es decir, los puntos críticos de J_0 son exactamente las soluciones de las ecuaciones normales $A^TAx = A^Tb$.

(a) ii.

Hessiana semidefinida positiva

Una matriz simétrica H es semidefinida positiva si

$$h^THh \geq 0 \quad \text{para todo } h \in \mathbb{R}^n.$$

Sea $h \in \mathbb{R}^n$. Usando la Hessiana obtenida antes,

$$h^TH_{J_0}h = h^T(2A^TA)h = 2\,(h^TA^T)(Ah).$$

Como $(PQ)^T = Q^T P^T$, se tiene que $h^T A^T = (Ah)^T$, luego

$$h^T H_{J_0} h = 2\,(Ah)^T (Ah).$$

Como $Ah \in \mathbb{R}^n$ es un vector columna y, para todo $w \in \mathbb{R}^n$, $w^T w = w_1^2 + \cdots + w_n^2 = \|w\|_2^2$,

$$h^T H_{J_0} h = 2\|Ah\|_2^2 \geq 0.$$

Por lo tanto, H_{J_0} es semidefinida positiva. No es necesariamente definida positiva, ya que si existe $h \neq 0$ con $Ah = 0$, entonces $h^T H_{J_0} h = 0$.

Taylor de segundo orden

Como J_0 es un polinomio de grado 2, su desarrollo de Taylor de segundo orden es exacto. Lo verificamos directamente. Sean $x_0, h \in \mathbb{R}^n$ y definimos

$$u = Ax_0 - b, \qquad v = Ah.$$

Entonces $A(x_0 + h) - b = (Ax_0 - b) + Ah = u + v$, y

$$J_0(x_0 + h) = \|u + v\|_2^2 = (u + v)^T (u + v) = u^T u + u^T v + v^T u + v^T v.$$

Como $u^T v$ es un número, es igual a su transpuesta: $u^T v = (u^T v)^T = v^T u$. Luego

$$J_0(x_0 + h) = u^T u + 2u^T v + v^T v.$$

Comparamos cada término con la expresión de Taylor $J_0(x_0) + \nabla J_0(x_0)^T h + \frac{1}{2} h^T H_{J_0} h$:

- $u^T u = (Ax_0 - b)^T (Ax_0 - b) = \|Ax_0 - b\|_2^2 = J_0(x_0)$.
- Usando $(PQ)^T = Q^T P^T$ y $(A^T)^T = A$,

$$\nabla J_0(x_0)^T h = \left[2A^T (Ax_0 - b)\right]^T h = 2(Ax_0 - b)^T Ah = 2u^T v.$$

- Como en la parte anterior,

$$\tfrac{1}{2} h^T H_{J_0} h = \tfrac{1}{2} h^T (2A^T A) h = (Ah)^T (Ah) = v^T v.$$

Por lo tanto, para todo $x_0, h \in \mathbb{R}^n$,

$$J_0(x_0 + h) = J_0(x_0) + \nabla J_0(x_0)^T h + \tfrac{1}{2} h^T H_{J_0} h,$$

con igualdad exacta.

Todo punto crítico es mínimo global

Sea x_0 un punto crítico de J_0, es decir, $\nabla J_0(x_0) = 0$, y sea $h \in \mathbb{R}^n$ cualquiera. Por el desarrollo de Taylor exacto,

$$J_0(x_0 + h) = J_0(x_0) + \nabla J_0(x_0)^T h + \tfrac{1}{2} h^T H_{J_0} h.$$

Como x_0 es punto crítico, $\nabla J_0(x_0)^T h = 0$:

$$J_0(x_0 + h) = J_0(x_0) + \tfrac{1}{2} h^T H_{J_0} h.$$

Por lo demostrado para la Hessiana, $\frac{1}{2} h^T H_{J_0} h = \|Ah\|_2^2$:

$$J_0(x_0 + h) = J_0(x_0) + \|Ah\|_2^2.$$

Como $\|Ah\|_2^2 \geq 0$:

$$J_0(x_0 + h) \geq J_0(x_0) \qquad \text{para todo } h \in \mathbb{R}^n.$$

Todo $x \in \mathbb{R}^n$ se escribe como $x = x_0 + h$ con $h = x - x_0$, luego

$$J_0(x) \geq J_0(x_0) \qquad \text{para todo } x \in \mathbb{R}^n.$$

Por definición, x_0 es un mínimo global de J_0.

(a) iii.

Como todo minimizador es punto crítico (teorema de Fermat), por (a) i. y (a) ii. los minimizadores de J_0 son exactamente las soluciones de las ecuaciones normales

$$A^T Ax = A^T b.$$

Además, $A^T A$ no es invertible si y solo si 0 es uno de sus valores propios.

El sistema tiene solución

Sea p la proyección ortogonal de b sobre $\text{Col}(A)$, el espacio generado por las columnas de A (Clase 10). Como $p \in \text{Col}(A)$, es combinación lineal de las columnas de A, por lo que existe x tal que $p = Ax$. Además, por definición de proyección ortogonal, $b - Ax$ es ortogonal a todas las columnas de A, lo que equivale a

$$A^T(b - Ax) = 0 \iff A^T Ax = A^T b.$$

Por lo tanto, las ecuaciones normales siempre tienen al menos una solución.

Caso 1: todos los valores propios de $A^T A$ son positivos

Como ningún valor propio es 0, la matriz $A^T A$ es invertible. Sean x_0 y x_1 dos soluciones del sistema. Restando $A^T Ax_0 = A^T b$ y $A^T Ax_1 = A^T b$,

$$A^T A(x_0 - x_1) = 0.$$

Multiplicando ambos lados por la izquierda por $(A^T A)^{-1}$,

$$(A^T A)^{-1} A^T A(x_0 - x_1) = (A^T A)^{-1} 0.$$

Como $(A^T A)^{-1} A^T A = I$ y toda matriz por el vector nulo da el vector nulo,

$$I(x_0 - x_1) = 0 \quad \iff \quad x_0 - x_1 = 0 \quad \iff \quad x_0 = x_1.$$

Es decir, dos soluciones cualesquiera coinciden. Como el sistema tiene al menos una solución, esta es única y J_0 tiene un único minimizador.

Caso 2: $A^T A$ tiene un valor propio nulo

Como 0 es valor propio de $A^T A$, existe $v \neq 0$ tal que

$$A^T Av = 0 \cdot v = 0.$$

Sea x_0 una solución del sistema y $t \in \mathbb{R}$. Distribuyendo, y usando que $A^T Ax_0 = A^T b$ y $A^T Av = 0$,

$$A^T A(x_0 + tv) = A^T Ax_0 + t\, A^T Av = A^T b + t \cdot 0 = A^T b,$$

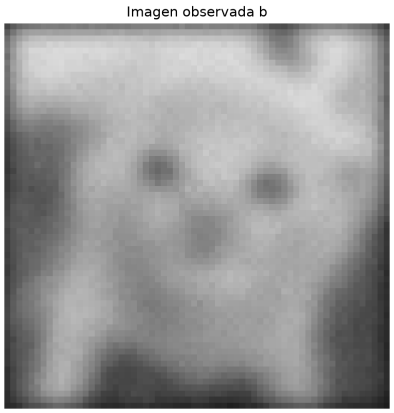
por lo que $x_0 + tv$ también es solución, para todo $t \in \mathbb{R}$. Como $v \neq 0$, si $t_1 \neq t_2$,

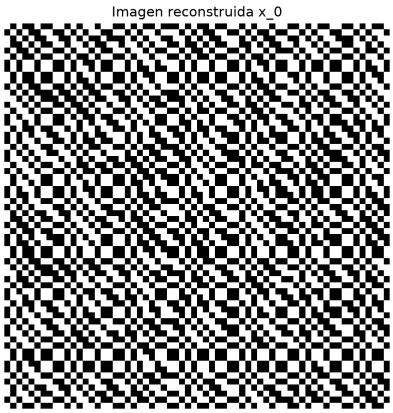
$$(x_0 + t_1 v) - (x_0 + t_2 v) = (t_1 - t_2)v \neq 0,$$

luego cada t entrega una solución distinta. Por lo tanto, el sistema tiene infinitas soluciones y J_0 tiene infinitos minimizadores.

(b) i.

Como todos los μ_i son positivos, por (a) iii J_0 tiene un único minimizador x_0, que coincide con la solución de $Ax = b$. Lo calculamos y obtenemos la imagen reconstruida.





Resultados. Se obtiene

$$\|x_0\|_2 \approx 992626, \qquad \max_i |x_{0,i}| \approx 55258, \qquad \|Ax_0 - b\|_2 \approx 1.5 \cdot 10^{-11}.$$

¿x_0 se parece a b? No, ya que mientras b muestra la imagen borrosa pero reconocible, x_0 solo muestra píxeles blancos y negros sin ninguna forma. Esto ocurre porque sus valores están muy fuera de $[0, 1]$, y al graficar con valores entre 0 y 1 se pierde información.

¿Se parece a una imagen? No. Los píxeles de una imagen están en $[0, 1]$, por lo que su norma es a lo más $\sqrt{n} = 64$ y su máximo es a lo más 1. En cambio, $\|x_0\|_2 \approx 992626$ y $\max_i |x_{0,i}| \approx 55258$, valores mucho mayores a los esperados.

Residuo. Como $\|Ax_0 - b\|_2 \approx 1.5 \cdot 10^{-11}$, x_0 resuelve $Ax = b$ casi exactamente. Sin embargo, como $b = Ax^* + \eta$, al ajustar b exactamente, x_0 también reproduce el ruido η. Por lo tanto, un residuo pequeño no implica una buena reconstrucción.

(b) ii.

Error en la dirección v_i. Como x_0 satisface las ecuaciones normales,

$$A^T A x_0 = A^T b.$$

Reemplazando $b = Ax^* + \eta$ y distribuyendo,

$$\begin{aligned} A^T A x_0 = A^T (Ax^* + \eta) &\iff A^T A x_0 = A^T A x^* + A^T \eta \\ &\iff A^T A x_0 - A^T A x^* = A^T \eta \\ &\iff A^T A (x_0 - x^*) = A^T \eta. \end{aligned}$$

Con producto interno con v_i en ambos lados,

$$\langle A^T A (x_0 - x^*), v_i \rangle = \langle A^T \eta, v_i \rangle.$$

Para simplificar usaremos que, para toda matriz M y vectores u, w,

$$\langle Mu, w \rangle = (Mu)^T w = u^T M^T w = \langle u, M^T w \rangle,$$

donde se usó $(PQ)^T = Q^T P^T$.

Lado izquierdo. Aplicando la propiedad con $M = A^T A$ y $u = x_0 - x^*$,

$$\langle A^T A(x_0 - x^*), v_i\rangle = \langle x_0 - x^*, (A^T A)^T v_i\rangle.$$

Como $A^T A$ es simétrica, $(A^T A)^T = A^T A$, luego

$$\langle x_0 - x^*, (A^T A)^T v_i\rangle = \langle x_0 - x^*, A^T A v_i\rangle.$$

Como v_i es vector propio de $A^T A$ con valor propio μ_i, se tiene $A^T A v_i = \mu_i v_i$, y como μ_i es un escalar, se sale del producto interno:

$$\langle x_0 - x^*, A^T A v_i\rangle = \langle x_0 - x^*, \mu_i v_i\rangle = \mu_i \langle x_0 - x^*, v_i\rangle.$$

Lado derecho. Aplicando la propiedad con $M = A^T$ y $u = \eta$, y usando $(A^T)^T = A$,

$$\langle A^T \eta, v_i\rangle = \langle \eta, (A^T)^T v_i\rangle = \langle \eta, A v_i\rangle = \langle A v_i, \eta\rangle,$$

donde en el último paso se usó la simetría del producto interno.

Igualando y juntando ambos lados,

$$\mu_i \langle x_0 - x^*, v_i\rangle = \langle A v_i, \eta\rangle,$$

y como $\mu_i > 0$, podemos dividir por μ_i:

$$\boxed{\langle x_0 - x^*, v_i\rangle = \frac{\langle A v_i, \eta\rangle}{\mu_i}.}$$

Cota. Tomando valor absoluto en el resultado anterior, y como $\mu_i > 0$,

$$|\langle x_0 - x^*, v_i\rangle| = \frac{|\langle A v_i, \eta\rangle|}{\mu_i}.$$

Para acotar el numerador usamos la desigualdad de Cauchy-Schwarz, $|\langle u, w\rangle| \leq \|u\|_2 \|w\|_2$, con $u = A v_i$ y $w = \eta$:

$$|\langle A v_i, \eta\rangle| \leq \|A v_i\|_2 \, \|\eta\|_2.$$

Calculamos $\|A v_i\|_2$,

$$\|A v_i\|_2^2 = (A v_i)^T (A v_i).$$

Usando $(PQ)^T = Q^T P^T$, se tiene $(A v_i)^T = v_i^T A^T$, luego

$$\|A v_i\|_2^2 = v_i^T A^T A v_i = v_i^T \left(A^T A v_i\right).$$

Como v_i es vector propio de $A^T A$ con valor propio μ_i, $A^T A v_i = \mu_i v_i$:

$$\|A v_i\|_2^2 = v_i^T (\mu_i v_i) = \mu_i \, v_i^T v_i.$$

Como los v_i son ortonormales, $v_i^T v_i = \|v_i\|_2^2 = 1$:

$$\|A v_i\|_2^2 = \mu_i \qquad \Longrightarrow \qquad \|A v_i\|_2 = \sqrt{\mu_i},$$

Reemplazando en la desigualdad de Cauchy-Schwarz,

$$|\langle x_0 - x^*, v_i\rangle| \leq \frac{\|A v_i\|_2 \, \|\eta\|_2}{\mu_i} = \frac{\sqrt{\mu_i}\, \|\eta\|_2}{\mu_i}.$$

Simplificando por $\sqrt{\mu_i}$,

$$\boxed{|\langle x_0 - x^*, v_i\rangle| \leq \frac{\|\eta\|_2}{\sqrt{\mu_i}}.}$$

¿Por qué es el error del ruido? El número $\langle x_0 - x^*, v_i \rangle$ mide cuánto se equivoca x_0 en la dirección v_i. Según la fórmula, ese error solo depende de η: si no hubiera ruido, el error sería 0 en todas las direcciones y obtendríamos exactamente $x_0 = x^*$. Por eso $\langle Av_i, \eta \rangle / \mu_i$ es el error que produce el ruido en la dirección v_i.

¿Por qué un ruido pequeño da un error tan grande? Como el ruido se divide por μ_i, mientras más pequeño es μ_i, más grande es. Con $\|\eta\|_2 \approx 0.64$, la cota $\|\eta\|_2 / \sqrt{\mu_i}$ da:

- si $\mu_i = 10^{-6}$: un error de hasta 640;
- si $\mu_i = \mu_{\min} \approx 2 \cdot 10^{-16}$: un error de hasta $4.5 \cdot 10^7$.

Como 1858 de los 4096 valores propios son menores que 10^{-6}, hay casi la mitad de las direcciones donde el ruido puede amplificarse cientos de veces o más. Todos estos errores se suman en x_0, y por eso $\|x_0\|_2 \approx 992626$, muy por encima de 64, aunque el ruido sea pequeño.

(c) i.

Para $\lambda > 0$, como se menciona en el enunciado

Gradiente de J_λ

Escribimos $J_\lambda(x) = J_0(x) + \lambda\, q(x)$, con q de (a) i evaluada en x. Entonces, $\nabla J_0(x) = 2A^T(Ax - b)$ y $\nabla q(x) = 2x$. Luego

$$\boxed{\nabla J_\lambda(x) = 2A^T(Ax - b) + 2\lambda x}$$

Hessiana de J_λ

Expandiendo y usando $\lambda x = \lambda I x$,

$$\nabla J_\lambda(x) = 2(A^TA + \lambda I)x - 2A^Tb.$$

Tiene la forma $Mx - c$ de (a) i, ahora con $M = 2(A^TA + \lambda I)$ y $c = 2A^Tb$. Por la misma idea,

$$\boxed{H_{J_\lambda} = 2(A^TA + \lambda I)}$$

Y es simétrica, ya que $(A^TA)^T = A^TA$ y $I^T = I$.

Valores propios de H_{J_λ}

Con v_i vector propio de A^TA, es decir, $A^TAv_i = \mu_i v_i$. Distribuyendo y usando $Iv_i = v_i$,

$$H_{J_\lambda} v_i = 2(A^TA + \lambda I)v_i = 2A^TAv_i + 2\lambda I v_i = 2\mu_i v_i + 2\lambda v_i = 2(\mu_i + \lambda)v_i.$$

Así v_i es vector propio de H_{J_λ} con valor propio $2(\mu_i + \lambda)$. Como los v_i forman una base ortonormal, estos son sus valores propios.

Para acotarlos, en (b) ii obtuvimos

$$\|Av_i\|_2^2 = (Av_i)^T(Av_i) = v_i^TA^TAv_i = v_i^T(\mu_i v_i) = \mu_i\, v_i^Tv_i = \mu_i,$$

usando $\|v_i\|_2 = 1$. Como una norma al cuadrado es no negativa,

$$\mu_i = \|Av_i\|_2^2 \geq 0 \quad \Longrightarrow \quad \mu_i + \lambda \geq \lambda \quad \Longrightarrow \quad 2(\mu_i + \lambda) \geq 2\lambda > 0.$$

Por lo tanto, H_{J_λ} es definida positiva.

Punto crítico

$$\nabla J_\lambda(x) = 0 \iff 2(A^TA + \lambda I)x = 2A^Tb \iff (A^TA + \lambda I)x = A^Tb.$$

Como $\mu_i + \lambda > 0$, 0 no es valor propio de $A^TA + \lambda I$, que es invertible. Luego

$$x_\lambda = (A^TA + \lambda I)^{-1}A^Tb$$

es el único punto crítico.

Mínimo global

Como J_λ es un polinomio de grado 2, su desarrollo de Taylor de segundo orden es exacto. Lo verificamos. Sean $x, h \in \mathbb{R}^n$. Por definición,

$$J_\lambda(x + h) = \|A(x + h) - b\|_2^2 + \lambda\|x + h\|_2^2 = J_0(x + h) + \lambda\|x + h\|_2^2.$$

Primer término. Por (a) ii,

$$J_0(x + h) = J_0(x) + \nabla J_0(x)^Th + \|Ah\|_2^2.$$

Segundo término. Usando $\|w\|_2^2 = w^T w$ y distribuyendo,

$$\lambda\|x+h\|_2^2 = \lambda(x+h)^T(x+h) = \lambda\left(x^Tx + x^Th + h^Tx + h^Th\right).$$

Como h^Tx es un número, es igual a su transpuesta: $h^Tx = (h^Tx)^T = x^Th$. Luego

$$\lambda\|x+h\|_2^2 = \lambda x^Tx + 2\lambda x^Th + \lambda h^Th = \lambda\|x\|_2^2 + (2\lambda x)^Th + \lambda\|h\|_2^2.$$

Sumando ambos términos y agrupando según el orden en h,

$$J_\lambda(x+h) = J_0(x) + \lambda\|x\|_2^2 + \left(\nabla J_0(x) + 2\lambda x\right)^T h + \|Ah\|_2^2 + \lambda\|h\|_2^2.$$

Comparamos cada término con la expresión de Taylor $J_\lambda(x) + \nabla J_\lambda(x)^T h + \frac{1}{2}h^T H_{J_\lambda} h$:

- $J_0(x) + \lambda\|x\|_2^2 = J_\lambda(x)$, por definición.
- $\nabla J_0(x) + 2\lambda x = 2A^T(Ax-b) + 2\lambda x = \nabla J_\lambda(x)$, por lo calculado antes.
- Distribuyendo y usando $h^TA^TAh = (Ah)^T(Ah)$,

$$\tfrac{1}{2}h^T H_{J_\lambda} h = \tfrac{1}{2}h^T\, 2(A^TA + \lambda I)h = h^TA^TAh + \lambda h^Th = \|Ah\|_2^2 + \lambda\|h\|_2^2.$$

Por lo tanto, para todo $x, h \in \mathbb{R}^n$,

$$J_\lambda(x+h) = J_\lambda(x) + \nabla J_\lambda(x)^T h + \tfrac{1}{2}h^T H_{J_\lambda} h,$$

con igualdad exacta.

Mínimo en x_λ. Evaluando en $x = x_\lambda$, como $\nabla J_\lambda(x_\lambda) = 0$, se tiene $\nabla J_\lambda(x_\lambda)^T h = 0$ y

$$J_\lambda(x_\lambda + h) = J_\lambda(x_\lambda) + \|Ah\|_2^2 + \lambda\|h\|_2^2.$$

Como $\|Ah\|_2^2 \geq 0$, y además $\lambda > 0$ y $\|h\|_2^2 > 0$ si $h \neq 0$,

$$J_\lambda(x_\lambda + h) \geq J_\lambda(x_\lambda) + \lambda\|h\|_2^2 > J_\lambda(x_\lambda) \qquad \text{para todo } h \neq 0.$$

Sea $x \in \mathbb{R}^n$ con $x \neq x_\lambda$, y definimos $h = x - x_\lambda$. Como $x \neq x_\lambda$, se tiene $h \neq 0$, y además

$$x_\lambda + h = x_\lambda + (x - x_\lambda) = x.$$

Reemplazando en la desigualdad anterior,

$$J_\lambda(x) = J_\lambda(x_\lambda + h) > J_\lambda(x_\lambda) \qquad \text{para todo } x \neq x_\lambda.$$

Por lo tanto, $x_\lambda = (A^TA + \lambda I)^{-1}A^Tb$ es el único minimizador global de J_λ.

(c) ii.

Componente de x_λ en la dirección v_i. Por (c) i, x_λ satisface

$$(A^TA + \lambda I)x_\lambda = A^Tb.$$

Reemplazando $b = Ax^* + \eta$ y distribuyendo,

$$\begin{aligned}(A^TA + \lambda I)x_\lambda &= A^T(Ax^* + \eta) \\ &= A^TAx^* + A^T\eta.\end{aligned}$$

Tomando producto interno con v_i en ambos lados,

$$\langle (A^TA + \lambda I)x_\lambda, v_i\rangle = \langle A^TAx^*, v_i\rangle + \langle A^T\eta, v_i\rangle.$$

Lado izquierdo. Como $A^TA + \lambda I$ es simétrica, y usando la propiedad $\langle Mu, w\rangle = \langle u, M^Tw\rangle$ de (b) ii,

$$\langle (A^TA + \lambda I)x_\lambda, v_i\rangle = \langle x_\lambda, (A^TA + \lambda I)v_i\rangle.$$

Como $A^TAv_i = \mu_i v_i$ e $Iv_i = v_i$,

$$(A^TA + \lambda I)v_i = \mu_i v_i + \lambda v_i = (\mu_i + \lambda)v_i.$$

Luego,

$$\langle (A^TA + \lambda I)x_\lambda, v_i\rangle = (\mu_i + \lambda)\langle x_\lambda, v_i\rangle.$$

Lado derecho. Usando que A^TA es simétrica y que $A^TAv_i = \mu_i v_i$,

$$\langle A^TAx^*, v_i\rangle = \langle x^*, A^TAv_i\rangle = \mu_i\langle x^*, v_i\rangle.$$

Además, como en (b) ii,

$$\langle A^T\eta, v_i\rangle = \langle Av_i, \eta\rangle.$$

Juntando ambos lados,

$$(\mu_i + \lambda)\langle x_\lambda, v_i\rangle = \mu_i\langle x^*, v_i\rangle + \langle Av_i, \eta\rangle.$$

Como $\mu_i \geq 0$ y $\lambda > 0$, podemos dividir por $\mu_i + \lambda$:

$$\boxed{\langle x_\lambda, v_i\rangle = \frac{\mu_i}{\mu_i + \lambda}\langle x^*, v_i\rangle + \frac{\langle Av_i, \eta\rangle}{\mu_i + \lambda}}$$

Cota del aporte del ruido. Como $\mu_i + \lambda > 0$,

$$\left|\frac{\langle Av_i, \eta\rangle}{\mu_i + \lambda}\right| = \frac{|\langle Av_i, \eta\rangle|}{\mu_i + \lambda}.$$

Por Cauchy-Schwarz, y usando que en (b) ii obtuvimos $\|Av_i\|_2 = \sqrt{\mu_i}$,

$$\frac{|\langle Av_i, \eta\rangle|}{\mu_i + \lambda} \leq \frac{\|Av_i\|_2\,\|\eta\|_2}{\mu_i + \lambda} = \frac{\sqrt{\mu_i}\,\|\eta\|_2}{\mu_i + \lambda}.$$

Por la indicación del enunciado, $\mu_i + \lambda \geq 2\sqrt{\mu_i\lambda}$. Por lo tanto,

$$\frac{\sqrt{\mu_i}}{\mu_i + \lambda} \leq \frac{1}{2\sqrt{\lambda}},$$

y concluimos que

$$\boxed{\left|\frac{\langle Av_i, \eta\rangle}{\mu_i + \lambda}\right| \leq \frac{\|\eta\|_2}{2\sqrt{\lambda}}}$$

Esta cota no depende de μ_i, por lo que se mantiene aunque μ_i sea muy pequeño.

Interpretación. La componente de x_λ en la dirección v_i es la suma de dos términos:

- $\dfrac{\mu_i}{\mu_i+\lambda}\langle x^*, v_i\rangle$ corresponde a la parte recuperada de la imagen verdadera. La componente original $\langle x^*, v_i\rangle$ se multiplica por el factor $\dfrac{\mu_i}{\mu_i+\lambda}$.
- $\dfrac{\langle Av_i, \eta\rangle}{\mu_i+\lambda}$ corresponde al aporte del ruido. Este término depende de η y sería 0 si no hubiera ruido.

(c) iii.

Por (c) ii, la parte recuperada de la imagen verdadera en la dirección v_i depende del factor

$$\frac{\mu_i}{\mu_i+\lambda}.$$

Si $\mu_i \gg \lambda$. En este caso, $\mu_i+\lambda$ es aproximadamente μ_i, por lo que

$$\frac{\mu_i}{\mu_i+\lambda} \approx 1.$$

Así, se recupera gran parte de la componente $\langle x^*, v_i\rangle$ de la imagen verdadera.

Si $\mu_i \ll \lambda$. En este caso, $\mu_i+\lambda$ es aproximadamente λ, por lo que

$$\frac{\mu_i}{\mu_i+\lambda} \approx \frac{\mu_i}{\lambda} \approx 0.$$

Así, esta componente de la imagen verdadera se atenúa. La regularización controla el aporte del ruido, pero también puede hacer perder información de la imagen.

Si λ es muy pequeño. El factor $\dfrac{\mu_i}{\mu_i+\lambda}$ se acerca a 1, por lo que se atenúan menos las componentes de la imagen verdadera. Sin embargo, la cota del aporte del ruido,

$$\frac{\|\eta\|_2}{2\sqrt{\lambda}},$$

aumenta al disminuir λ. Por lo tanto, el ruido puede amplificarse más. Como todos los μ_i son positivos en este problema, al acercar λ a 0 la reconstrucción se aproxima a x_0, que en (b) resultó inestable.

Si λ es muy grande. La cota del aporte del ruido disminuye, pero el factor $\dfrac{\mu_i}{\mu_i+\lambda}$ también se acerca a 0. Por lo tanto, se atenúan tanto el ruido como las componentes de la imagen verdadera. Al crecer λ, x_λ se aproxima al vector cero y la reconstrucción pierde información.

En consecuencia, elegir λ requiere un equilibrio, si es muy pequeño, puede mantenerse la amplificación del ruido, y si es muy grande, se pierde información de la imagen verdadera.

(c) iv.

Calculamos x_λ resolviendo $(A^TA+\lambda I)\,x = A^Tb$ para $\lambda \in \{10^{-3.5}, 10^{-2.5}, 1\}$, y lo comparamos con b y x_0.

Resultados. Para x_0 se obtiene

$$\|x_0\|_2 \approx 992626, \qquad \|Ax_0 - b\|_2 \approx 1.5\cdot 10^{-11}.$$

Para $\lambda = 10^{-3.5}$,

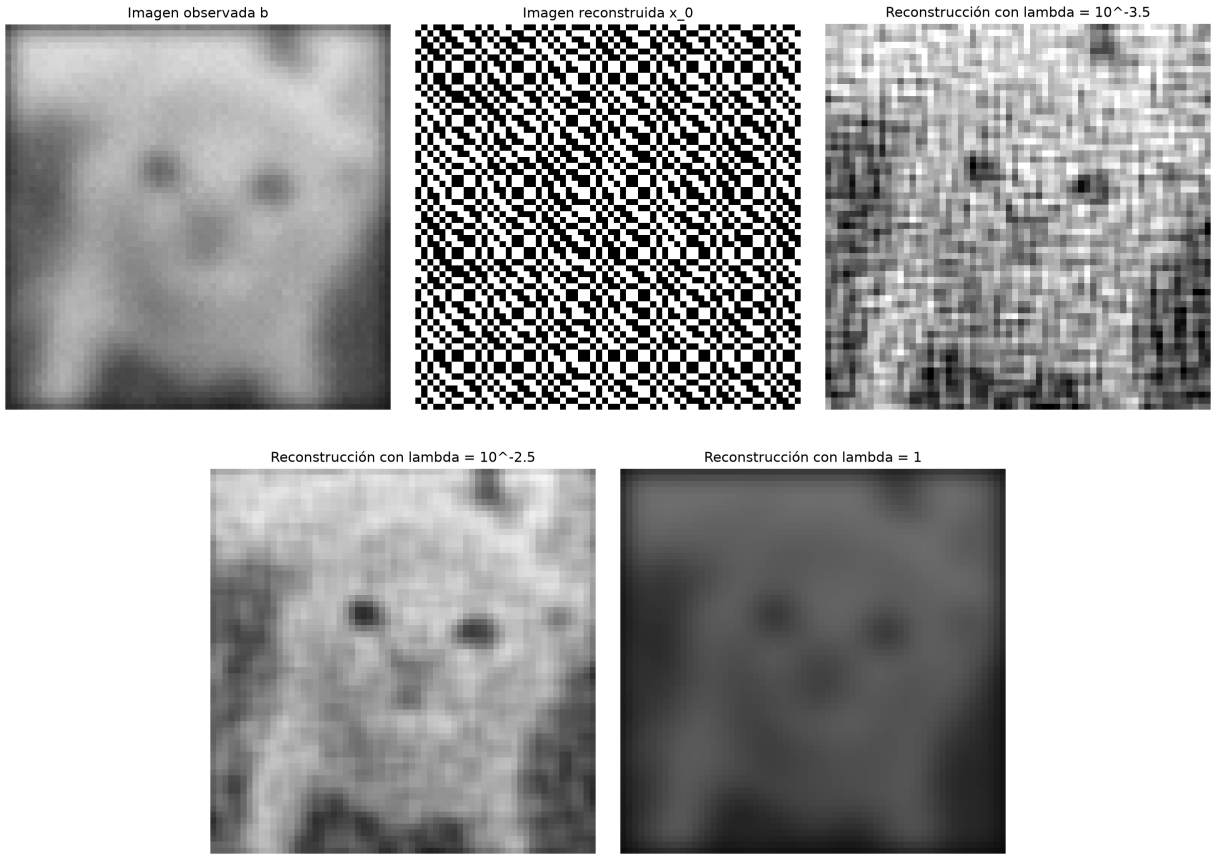
$$\|x_\lambda\|_2 \approx 41.1, \qquad \|Ax_\lambda - b\|_2 \approx 0.55.$$

Para $\lambda = 10^{-2.5}$,

$$\|x_\lambda\|_2 \approx 40.2, \qquad \|Ax_\lambda - b\|_2 \approx 0.61.$$

Para $\lambda = 1$,

$$\|x_\lambda\|_2 \approx 19.3, \qquad \|Ax_\lambda - b\|_2 \approx 19.98.$$



Comparación con x_0. Las tres reconstrucciones tienen norma menor a $\sqrt{n} = 64$, mientras que $\|x_0\|_2 \approx 992626$. Esto pasa porque, por (b) ii, en x_0 el error del ruido en la dirección v_i está acotado por $\|\eta\|_2/\sqrt{\mu_i}$, y como hay μ_i muy pequeños el error puede ser muy grande. Por ejemplo, con $\mu_{min} \approx 2 \cdot 10^{-16}$,

$$\frac{\|\eta\|_2}{\sqrt{\mu_{min}}} \approx \frac{0.64}{\sqrt{2 \cdot 10^{-16}}} \approx \frac{0.64}{1.41 \cdot 10^{-8}} \approx 4.5 \cdot 10^7.$$

En cambio, por (c) ii, en x_λ el aporte del ruido queda acotado por $\|\eta\|_2/(2\sqrt{\lambda})$, que no depende de μ_i, es decir, para un λ fijo es la misma cota en todas las direcciones v_i, incluso en las que tienen μ_i muy pequeño. Con $\|\eta\|_2 \approx 0.64$, esta cota vale

$$\lambda = 10^{-3.5}: \quad \frac{0.64}{2\sqrt{10^{-3.5}}} \approx \frac{0.64}{2 \cdot 0.0178} \approx 18,$$

$$\lambda = 10^{-2.5}: \quad \frac{0.64}{2\sqrt{10^{-2.5}}} \approx \frac{0.64}{2 \cdot 0.0562} \approx 5.7,$$

$$\lambda = 1: \quad \frac{0.64}{2\sqrt{1}} = 0.32.$$

Así, el ruido tiene un límite que no puede superar, sin importar la dirección, y por eso se puede ver una imagen.

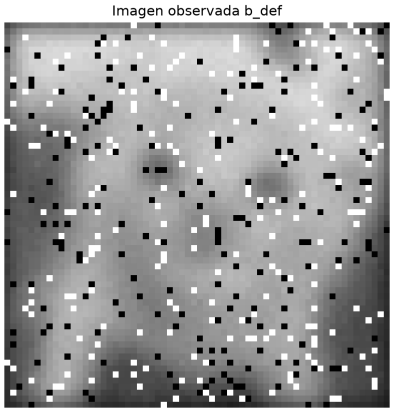
$\lambda = 10^{-3.5}$. Se reconoce la imagen, pero con algunos patrones raros. Por (c) iii, como λ es pequeño, el límite del ruido es mayor (≈ 18, a diferencia de ≈ 5.7 con $\lambda = 10^{-2.5}$), por lo que entra más ruido. Además, su residuo ≈ 0.55 es menor que $\delta = 0.64$, es decir, se ajusta a b más de lo que debería y también reproduce parte del ruido.

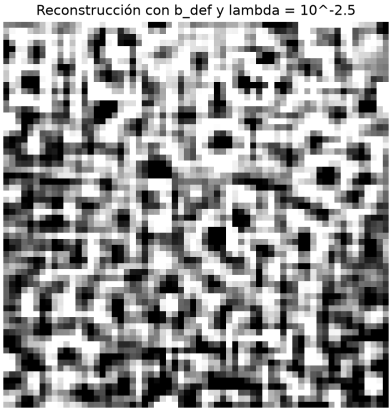
$\lambda = 1$**.** La imagen se ve oscura y borrosa, ya que se pierde información de la imagen. Por (c) iii, como λ es grande, el factor $\mu_i/(\mu_i + \lambda)$ se acerca a 0 en las direcciones con $\mu_i \ll \lambda$, y como hay muchos μ_i pequeños (1858 menores que 10^{-6}), esas componentes de la imagen prácticamente desaparecen. El ruido se elimina, pero también parte de la información, por eso su norma es la menor (≈ 19.3) y su residuo ≈ 20 es mucho mayor que δ.

¿Cuál es la mejor? La mejor reconstrucción es con $\lambda = 10^{-2.5}$, ya que es la que mejor se entiende y su residuo ≈ 0.61 es el más cercano a $\delta = 0.64$. Es decir, se ajusta a b solo hasta el nivel del ruido, equilibrando recuperar la imagen y controlar el ruido.

(d)

Reconstruimos la imagen a partir de $\tilde{b}$ con la regularización de Tikhonov y $\lambda = 10^{-2.5}$, resolviendo $(A^TA + \lambda I)\, x = A^T\tilde{b}$ como en (c) iv.





Resultados. Se obtiene

$$\|x_\lambda\|_2 \approx 48.7, \qquad \|Ax_\lambda - \tilde{b}\|_2 \approx 10.1,$$

mientras que con b y el mismo λ se tenía $\|x_\lambda\|_2 \approx 40.2$ y $\|Ax_\lambda - b\|_2 \approx 0.61$.

Con el mismo λ que en (c) iv dio la mejor reconstrucción, ahora la imagen no se reconoce y solo se observa un patrón desordenado de manchas blancas y negras. La norma es parecida a la obtenida con b, pero el residuo es mucho mayor que $\delta = 0.64$. Esto ocurre porque la reconstrucción intenta ajustarse también a las lecturas de los píxeles dañados, que no corresponden a ninguna imagen.

(d) i.

De $b = Ax^* + \eta$, despejando,

$$Ax^* = b - \eta.$$

Reemplazando en $\tilde{b} = Ax^* + \tilde{\eta}$,

$$\begin{aligned} \tilde{b} = (b - \eta) + \tilde{\eta} &\iff \tilde{\eta} = \tilde{b} - b + \eta \\ &\iff \boxed{\tilde{\eta} = \eta + (\tilde{b} - b).} \end{aligned}$$

Interpretación. El ruido de $\tilde{b}$ es el ruido del sensor más el error que introducen los píxeles dañados.

- η es el ruido del sensor, el mismo de la observación b, y es pequeño: $\|\eta\|_2 \approx 0.64$.
- $\tilde{b} - b$ es el error de los píxeles dañados. Si el píxel p está bien, registra lo mismo en ambas observaciones y $\tilde{b}_p - b_p = 0$, por lo que $\tilde{\eta}_p = \eta_p$. Si está dañado, $\tilde{b}_p$ vale 0 o 1 sin importar la imagen, por lo que $\tilde{b}_p - b_p$ es un error sin relación con x^*. En los datos, $\tilde{b} - b$ es distinto de cero en 430 de los 4096 píxeles, cerca del 10%.

(d) ii.

Al calcular nos queda que $\|\tilde{b} - b\|_2 \approx 10.88$. No podemos calcular $\tilde{\eta}$ directamente, ya que no conocemos η, solo $\|\eta\|_2 \approx \delta = 0.64$. Por eso acotamos su norma con la desigualdad triangular, $\|u + w\|_2 \leq \|u\|_2 + \|w\|_2$.

Cota superior. Por (d) i,

$$\|\tilde{\eta}\|_2 = \|\eta + (\tilde{b} - b)\|_2 \leq \|\eta\|_2 + \|\tilde{b} - b\|_2 \approx 0.64 + 10.88 = 11.52.$$

Cota inferior. Despejando en (d) i, $\tilde{b}-b=\tilde{\eta}+(-\eta)$. Por la desigualdad triangular, y como $\|-\eta\|_2=\|\eta\|_2$,

$$\|\tilde{b}-b\|_2 \le \|\tilde{\eta}\|_2+\|\eta\|_2 \quad\Longrightarrow\quad \|\tilde{\eta}\|_2 \ge \|\tilde{b}-b\|_2-\|\eta\|_2 \approx 10.88-0.64=10.24.$$

Comparación con δ. Juntando ambas cotas,

$$10.24 \lesssim \|\tilde{\eta}\|_2 \lesssim 11.52.$$

Dividiendo por $\delta=0.64$, se tiene $10.24/0.64=16$ y $11.52/0.64=18$, por lo que el ruido de $\tilde{b}$ está entre 16 y 18 veces mayor que δ. Casi todo proviene de los píxeles dañados, ya que $\|\eta\|_2\approx 0.64$ es pequeño comparado con $\|\tilde{b}-b\|_2\approx 10.88$.

(d) iii.

Con (c) ii, reemplazando η por $\tilde{\eta}$, el aporte del ruido en cada dirección v_i cumple

$$\frac{|\langle Av_i,\tilde{\eta}\rangle|}{\mu_i+\lambda} \le \frac{\|\tilde{\eta}\|_2}{2\sqrt{\lambda}},$$

mientras que la parte recuperada de x^* no cambia, ya que solo depende de x^*.

¿Por qué fracasa? Por (d) ii, $\|\tilde{\eta}\|_2$ está entre 16 y 18 veces δ, por lo que con el mismo $\lambda=10^{-2.5}$, el aporte del ruido puede ser hasta unas 17 veces mayor que con b. En (c) iv este aporte era pequeño frente a la parte de x^* y se reconocía la imagen, ahora el ruido afecta aún más y la reconstrucción queda como un patrón desordenado de manchas blancas y negras.

¿Bastaría con aumentar λ? No. Como la cota disminuye como $1/\sqrt{\lambda}$, para reducir el aporte del ruido unas 17 veces habría que aumentar λ unas $17^2\approx 289$ veces. Si tomamos $\|\tilde{\eta}\|_2\approx 17\delta$ y $17^2\lambda$ en lugar de λ,

$$\frac{\|\tilde{\eta}\|_2}{2\sqrt{17^2\lambda}} \approx \frac{17\delta}{2\cdot 17\sqrt{\lambda}} = \frac{\delta}{2\sqrt{\lambda}},$$

que es la cota que se tenía con b, lo que requiere usar $17^2\lambda\approx 289\cdot 10^{-2.5}\approx 1$. Pero en (c) iv se vio que con $\lambda=1$ la reconstrucción queda oscura y borrosa. Por lo tanto, aumentar λ elimina el ruido, pero también afecta a la imagen.

Bonus

Construcción de w. Por (d) i, $\tilde{\eta}=\eta+(\tilde{b}-b)$. Los píxeles sin problema registran lo mismo en ambas observaciones, por lo que $\tilde{b}_p-b_p=0$ si el píxel p está bien, y $\tilde{b}_p-b_p\neq 0$ si está dañado. Así, definimos

$$w_p=\begin{cases}1 & \text{si } \tilde{b}_p=b_p,\\ 0 & \text{si } \tilde{b}_p\neq b_p.\end{cases}$$

En los datos, 430 de los 4096 píxeles están dañados, cerca del 10%.

Gradiente de J_W. Como $W=\mathrm{diag}(w)$, se tiene

$$(Ax-\tilde{b})^TW(Ax-\tilde{b})=\sum_{p=1}^{n} w_p\big((Ax)_p-\tilde{b}_p\big)^2,$$

por lo que los píxeles con $w_p=0$ no aparecen en la suma. Siguiendo el procedimiento de (a) i, escribimos

$$r(x)=Ax-\tilde{b}, \qquad q_W(u)=u^TWu=\sum_{p=1}^{n} w_pu_p^2,$$

de modo que $J_W(x) = q_W(r(x)) + \lambda\|x\|_2^2$. Como en (a) i, $Dr(x) = A$. Derivando q_W respecto de u_p, solo sobrevive el término con índice p:

$$\frac{\partial q_W}{\partial u_p}(u) = 2w_p u_p, \qquad \text{luego} \qquad Dq_W(u) = \begin{pmatrix} 2w_1u_1 & 2w_2u_2 & \cdots & 2w_nu_n \end{pmatrix} = 2u^T W.$$

Por la regla de la cadena, evaluando Dq_W en $u = r(x) = Ax - \tilde{b}$,

$$D(q_W \circ r)(x) = Dq_W(r(x))\, Dr(x) = 2(Ax - \tilde{b})^T W A.$$

Transponiendo, y usando $(PQR)^T = R^T Q^T P^T$ y $W^T = W$ (por ser diagonal),

$$\nabla(q_W \circ r)(x) = \big(2(Ax - \tilde{b})^T W A\big)^T = 2A^T W^T \big((Ax - \tilde{b})^T\big)^T = 2A^T W(Ax - \tilde{b}).$$

Finalmente, por (c) i, el gradiente de $\lambda\|x\|_2^2$ es $2\lambda x$. Sumando,

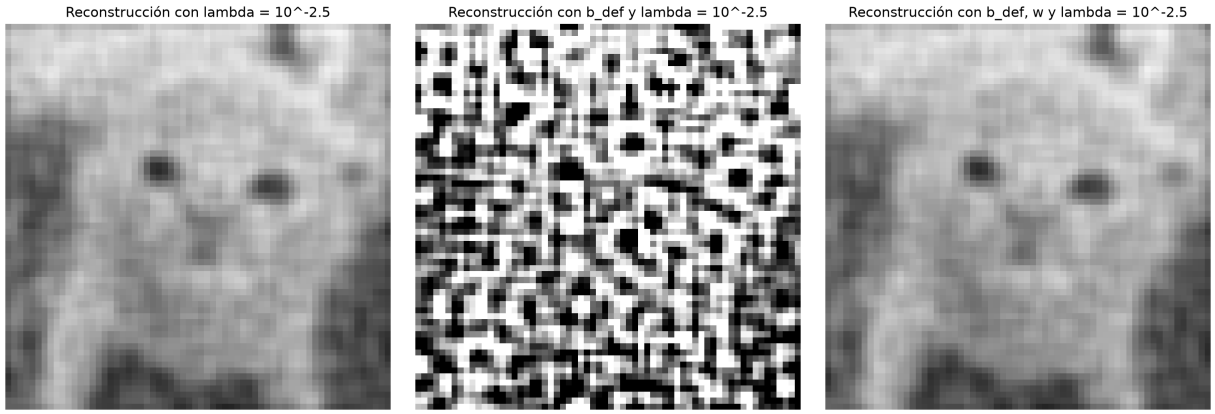
$$\nabla J_W(x) = 2A^T W(Ax - \tilde{b}) + 2\lambda x.$$

Punto crítico. Igualando el gradiente a cero,

$$2A^T W(Ax - \tilde{b}) + 2\lambda x = 0 \iff A^T W Ax + \lambda x = A^T W\tilde{b} \iff (A^T W A + \lambda I)\, x = A^T W\tilde{b},$$

que es el sistema que se resuelve en el notebook.

Resultado. Resolviendo el sistema anterior con $\lambda = 10^{-2.5}$, como en (d), se obtienen las reconstrucciones de la figura.



Al ignorar los píxeles dañados, la reconstrucción queda prácticamente igual a la obtenida a partir de b en (c) iv, mientras que sin w se obtiene un patrón desordenado de manchas blancas y negras. El residuo sobre los píxeles que están bien es ≈ 0.58, cercano a $\delta = 0.64$, como en la mejor reconstrucción de (c) iv. Esto funciona porque, aunque se pierde cerca del 10% de las lecturas, cada píxel de la imagen influye en hasta 81 de ellas, así que aún le quedan aproximadamente unas 73 lecturas, información suficiente para reconstruirlo.

2 Pregunta 2

Inciso (a)

Satisfacibilidad Considerando la sigmoide $\sigma(t) = \frac{1}{1+e^{-t}}$, queremos demostrar que satisface $\sigma'(t) = \sigma(t)\big(1 - \sigma(t)\big)$ Derivamos usando la regla de la cadena

$$\sigma'(t) = -\left(1 + e^{-t}\right)^{-2} \cdot (-e^{-t}) = \frac{e^{-t}}{(1+e^{-t})^2}$$

Separamos factorizando $\sigma(t)$

$$\sigma'(t) = \frac{1}{1+e^{-t}} \cdot \frac{e^{-t}}{1+e^{-t}} = \sigma(t) \cdot \frac{e^{-t}}{1+e^{-t}}$$

Luego notamos que el segundo término es $1 - \sigma(t)$

$$1 - \sigma(t) = 1 - \frac{1}{1+e^{-t}} = \frac{(1+e^{-t}) - 1}{1+e^{-t}} = \frac{e^{-t}}{1+e^{-t}}$$

Por lo tanto, queda demostrado que $\sigma'(t) = \sigma(t)\big(1 - \sigma(t)\big)$

Máximo. Para acotar $\sigma'(t)$ estudiamos sus extremos y buscamos sus puntos críticos derivando por segunda vez e igualando a cero

$$\sigma''(t) = \sigma'(t)\big(1 - \sigma(t)\big) + \sigma(t)\big(-\sigma'(t)\big) = \sigma'(t)\big(1 - 2\sigma(t)\big)$$

Se tiene $\sigma''(t) = 0$ si y solo si $1 - 2\sigma(t) = 0$, entonces $\sigma(t) = \frac{1}{2}$

$$\frac{1}{1+e^{-t}} = \frac{1}{2} \quad \Longrightarrow \quad 1 + e^{-t} = 2 \quad \Longrightarrow \quad e^{-t} = 1 \quad \Longrightarrow \quad t = 0$$

Para verificar que $t = 0$ es un máximo, estudiamos el signo de $\sigma''(t) = \sigma'(t)\big(1 - 2\sigma(t)\big)$. Como $\sigma'(t) > 0$, σ es creciente y como $\sigma(0) = \frac{1}{2}$,

$$t < 0: \quad \sigma(t) < \tfrac{1}{2} \implies 1 - 2\sigma(t) > 0 \implies \sigma''(t) > 0$$

$$t > 0: \quad \sigma(t) > \tfrac{1}{2} \implies 1 - 2\sigma(t) < 0 \implies \sigma''(t) < 0$$

Así σ' crece antes de $t = 0$ y decrece después, por lo que σ' alcanza su máximo en $t = 0$

$$\sigma'(0) = \sigma(0)\big(1 - \sigma(0)\big) = \tfrac{1}{2} \cdot \tfrac{1}{2} = \tfrac{1}{4}$$

En el notebook verificamos esto numéricamente en 20 valores de t al azar en [-5,5] con la derivada por diferencias centradas coincide con $\sigma(t)\big(1 - \sigma(t)\big)$ y aplicando lo mismo a σ' obtenemos σ'', que cambia de signo en $t = 0$, donde $\sigma'(0) = 0.25$ y es creciente

Cota. Acotamos $\sigma'(t)$ por ambos lados $0 < \sigma(t) < 1$, ya que $\sigma(t)$ y $1 - \sigma(t)$ son positivos, luego su producto es estrictamente positivo. Por otro lado el máximo hallado muestra que el mayor valor que toma $\sigma'(t)$ es $\frac{1}{4}$, alcanzado en $t = 0$, entonces

$$0 < \sigma'(t) \leq \tfrac{1}{4} \qquad \text{para todo } t \in \mathbb{R}$$

Inciso (b)

$$x_i \longrightarrow z_{1,i} \longrightarrow h_{1,i} \longrightarrow z_{2,i} \longrightarrow h_{2,i} \longrightarrow \hat{y}_i \longrightarrow e_i \longrightarrow L_i$$

Derivadas. Por la regla de la cadena usamos en cada capa $\sigma'(t) = \sigma(t)\big(1-\sigma(t)\big)$ de (a)
Pérdida y error

$$\frac{\partial L_i}{\partial e_i} = \frac{1}{2}\cdot 2e_i = e_i, \qquad \frac{\partial e_i}{\partial \hat{y}_i} = 1$$

Capa de salida $\hat{y}_i = c + v\, h_{2,i}$

$$\frac{\partial \hat{y}_i}{\partial c} = 1, \qquad \frac{\partial \hat{y}_i}{\partial v} = h_{2,i}, \qquad \frac{\partial \hat{y}_i}{\partial h_{2,i}} = v$$

Capa oculta 2 $h_{2,i} = \sigma(z_{2,i})$ y $z_{2,i} = a_2 h_{1,i} + b_2$

$$\frac{\partial h_{2,i}}{\partial z_{2,i}} = h_{2,i}(1-h_{2,i}), \qquad \frac{\partial z_{2,i}}{\partial b_2} = 1, \qquad \frac{\partial z_{2,i}}{\partial a_2} = h_{1,i}, \qquad \frac{\partial z_{2,i}}{\partial h_{1,i}} = a_2$$

Capa oculta 1 $h_{1,i} = \sigma(z_{1,i})$ y $z_{1,i} = a_1 x_i + b_1$

$$\frac{\partial h_{1,i}}{\partial z_{1,i}} = h_{1,i}(1-h_{1,i}), \qquad \frac{\partial z_{1,i}}{\partial b_1} = 1, \qquad \frac{\partial z_{1,i}}{\partial a_1} = x_i$$

Agrupamos parametros. Capa de salida $c \to \hat{y}_i \to e_i \to L_i$ y $v \to \hat{y}_i \to e_i \to L_i$

$$\frac{\partial L_i}{\partial c} = \frac{\partial L_i}{\partial e_i}\cdot\frac{\partial e_i}{\partial \hat{y}_i}\cdot\frac{\partial \hat{y}_i}{\partial c} = e_i, \qquad \frac{\partial L_i}{\partial v} = \frac{\partial L_i}{\partial e_i}\cdot\frac{\partial e_i}{\partial \hat{y}_i}\cdot\frac{\partial \hat{y}_i}{\partial v} = e_i\, h_{2,i}$$

Capa oculta 2: $b_2, a_2 \to z_{2,i} \to h_{2,i} \to \hat{y}_i \to e_i \to L_i$

$$\frac{\partial L_i}{\partial b_2} = \frac{\partial L_i}{\partial e_i}\cdot\frac{\partial e_i}{\partial \hat{y}_i}\cdot\frac{\partial \hat{y}_i}{\partial h_{2,i}}\cdot\frac{\partial h_{2,i}}{\partial z_{2,i}}\cdot\frac{\partial z_{2,i}}{\partial b_2} = e_i\, v\, h_{2,i}(1-h_{2,i})$$

$$\frac{\partial L_i}{\partial a_2} = \frac{\partial L_i}{\partial e_i}\cdot\frac{\partial e_i}{\partial \hat{y}_i}\cdot\frac{\partial \hat{y}_i}{\partial h_{2,i}}\cdot\frac{\partial h_{2,i}}{\partial z_{2,i}}\cdot\frac{\partial z_{2,i}}{\partial a_2} = e_i\, v\, h_{2,i}(1-h_{2,i})\, h_{1,i}$$

Capa oculta 1: $b_1, a_1 \to z_{1,i} \to h_{1,i} \to z_{2,i} \to h_{2,i} \to \hat{y}_i \to e_i \to L_i$

$$\frac{\partial L_i}{\partial b_1} = \frac{\partial L_i}{\partial e_i}\cdot\frac{\partial e_i}{\partial \hat{y}_i}\cdot\frac{\partial \hat{y}_i}{\partial h_{2,i}}\cdot\frac{\partial h_{2,i}}{\partial z_{2,i}}\cdot\frac{\partial z_{2,i}}{\partial h_{1,i}}\cdot\frac{\partial h_{1,i}}{\partial z_{1,i}}\cdot\frac{\partial z_{1,i}}{\partial b_1} = e_i\, v\, h_{2,i}(1-h_{2,i})\, a_2\, h_{1,i}(1-h_{1,i})$$

$$\frac{\partial L_i}{\partial a_1} = \frac{\partial L_i}{\partial e_i}\cdot\frac{\partial e_i}{\partial \hat{y}_i}\cdot\frac{\partial \hat{y}_i}{\partial h_{2,i}}\cdot\frac{\partial h_{2,i}}{\partial z_{2,i}}\cdot\frac{\partial z_{2,i}}{\partial h_{1,i}}\cdot\frac{\partial h_{1,i}}{\partial z_{1,i}}\cdot\frac{\partial z_{1,i}}{\partial a_1} = e_i\, v\, h_{2,i}(1-h_{2,i})\, a_2\, h_{1,i}(1-h_{1,i})\, x_i$$

Gradiente. Juntamos las seis derivadas en el orden $\theta = (a_1, b_1, a_2, b_2, v, c)$, y como $J = \frac{1}{N}\sum_{i=1}^{N} L_i$, su gradiente es el promedio sobre los N datos

$$\nabla_\theta J(\theta) = \frac{1}{N}\sum_{i=1}^{N}\left(\frac{\partial L_i}{\partial a_1},\ \frac{\partial L_i}{\partial b_1},\ \frac{\partial L_i}{\partial a_2},\ \frac{\partial L_i}{\partial b_2},\ \frac{\partial L_i}{\partial v},\ \frac{\partial L_i}{\partial c}\right) \in \mathbb{R}^6$$

Inciso (c)

Implementación. A partir de los datos con $N = 200$ pares (x_i, y_i) se programaron en `Python` con `pandas` y `Numpy` las funciones

$$J(\theta) = \frac{1}{2N}\sum_{i=1}^{N} e_i^2, \qquad e_i = \hat{y}_i - y_i, \quad \hat{y}_i = c + v\, h_{2,i},$$

con paso capa por capa $z_{1,i} = a_1 x_i + b_1$, $h_{1,i} = \sigma(z_{1,i})$, $z_{2,i} = a_2 h_{1,i} + b_2$, $h_{2,i} = \sigma(z_{2,i})$, y su gradiente $\nabla_\theta J(\theta) \in \mathbb{R}^6$ por regla de la cadena promediando $\frac{\partial J}{\partial \theta^{(j)}} = \frac{1}{N}\sum_{i=1}^{N} \frac{\partial L_i}{\partial \theta^{(j)}}$ con $L_i = \frac{1}{2}e_i^2$. Cada derivada parcial se calculó con la definición $\sigma'(t) = \sigma(t)(1 - \sigma(t))$ de (a). Las diferencias centradas $f'(u) = \frac{f(u+h)-f(u-h)}{2h}$ se usaron solo para verificar estas fórmulas

Usando semilla `np.random.seed(0)` y $\theta_0 \sim U[-1, 1]^6$:

$$\theta_0 = (0.097627,\ 0.430379,\ 0.205527,\ 0.089766,\ -0.152690,\ 0.291788)$$

en orden $\theta = (a_1, b_1, a_2, b_2, v, c)$. Se obtuvo

$$J(\theta_0) = 0.603522343354513,$$

$$\nabla_\theta J(\theta_0) = (-0.000862,\ 0.001382,\ 0.016455,\ 0.027827,\ -0.407364,\ -0.737138).$$

Verificación. Comparando cada componente con diferencias centradas

$$D_j = \frac{J(\theta_0 + he_j) - J(\theta_0 - he_j)}{2h}, \quad h = 10^{-5},\ j = 1, \ldots, 6,$$

se obtuvo

$$D = (-0.000862,\ 0.001382,\ 0.016455,\ 0.027827,\ -0.407364,\ -0.737138),$$

$$E = \max_{j=1,\ldots,6} \left| \frac{\partial J}{\partial \theta^{(j)}}(\theta_0) - D_j \right| = 1.65 \times 10^{-11}.$$

Como $E \approx 10^{-11} \ll 10^{-8}$, el gradiente programado pasa la verificación. Las componentes asociadas a (a_1, b_1) son $\sim 10^{-3}$ por el producto $\sigma'(z_{1,i})\sigma'(z_{2,i}) \leq 1/16$.

Inciso (d)

Descenso del gradiente. Partiendo del mismo θ_0 del inciso (c) se iteró

$$\theta_{k+1} = \theta_k - \alpha \nabla J(\theta_k), \qquad \alpha = 1,$$

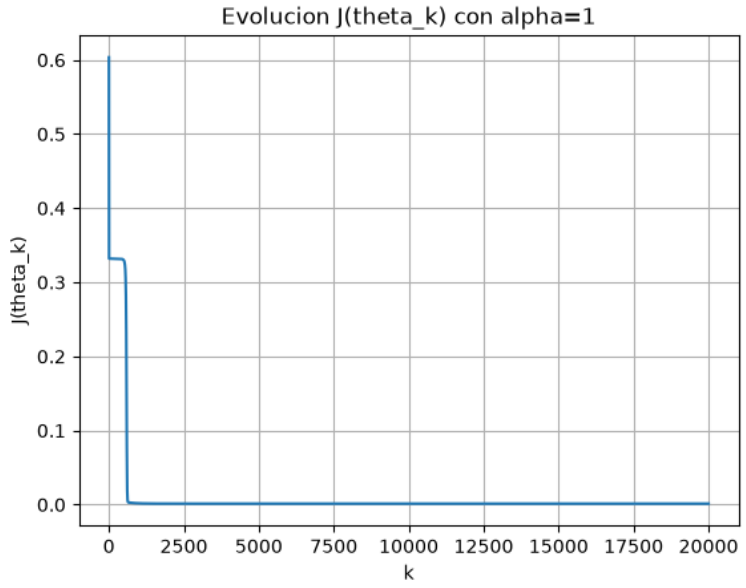
por 20 000 iteraciones. Se obtuvo

$$\theta_{20000} = (-4.366759,\ -0.747365,\ 3.555817,\ -1.627432,\ 2.960878,\ -0.439813),$$

$$J(\theta_{20000}) = 0.001373561381571473, \|\nabla J(\theta_{20000})\|_2 = 1.0664573822465625 \cdot 10^{-5}$$

frente a $J(\theta_0) = 0.603522343354513$, es decir una reducción de dos órdenes de magnitud. Los valores $|a_1|, |a_2| > 3$ son esperables para generar pendientes pronunciadas en la sigmoide.

La evolución $J(\theta_k)$ versus k se muestra en la Figura.



Se observa una meseta inicial hasta $k \approx 400$ con $J \approx 0.35$–0.32, producto de $\sigma'(t) \leq 1/4$ y por tanto $\|\nabla J\|$ pequeño en las capas internas ($\partial J/\partial a_1, \partial J/\partial b_1$ contienen $\sigma'(z_{1,i})\sigma'(z_{2,i})$). Entre $k \approx 500$ y $k \approx 1000$ ocurre una caída brusca de J de ~ 0.32 a < 0.01 al salir de la zona de saturación de σ. Desde $k \gtrsim 1500$ el error se estabiliza en $J \approx 0.00137$ hasta $k = 20000$, visible como recta horizontal, indicando convergencia a un mínimo local con $\nabla J(\theta_{20000}) \approx 0$.

Inciso (e)

En el inciso (d), desde θ_0 aplicamos 20.000 veces el descenso del gradiente $\theta_{k+1} = \theta_k - \alpha\,\nabla J(\theta_k), \qquad \alpha = 1$ obteniendo $\theta_{20.000}$. En el notebook, primero separamos sus seis parámetros, $\theta_{20.000} = (a_1, b_1, a_2, b_2, v, c)$. Luego para obtener la curva $x \mapsto \hat{y}(x; \theta_{20.000})$, tomamos 100 valores de x en $[-1, 1]$ y para cada uno calculamos capa por capa su salida

Entrada: x

Capa oculta 1: $z_1 = a_1 x + b_1$ luego aplicamos la sigmoide de (a) a z_1

$$h_1 = \sigma(z_1) = \frac{1}{1 + e^{-z_1}} = \frac{1}{1 + e^{-(a_1 x + b_1)}}$$

Capa oculta 2: $z_2 = a_2 h_1 + b_2$ luego aplicamos la sigmoide a z_2

$$h_2 = \sigma(z_2) = \frac{1}{1 + e^{-z_2}} = \frac{1}{1 + e^{-(a_2 h_1 + b_2)}}$$

Capa de salida: $\hat{y} = c + v\,h_2$

Reemplazando $h_1 = \sigma(a_1 x + b_1)$ en z_2, y luego $h_2 = \sigma(z_2)$ en $\hat{y}$, obtenemos la salida de la red para cada x

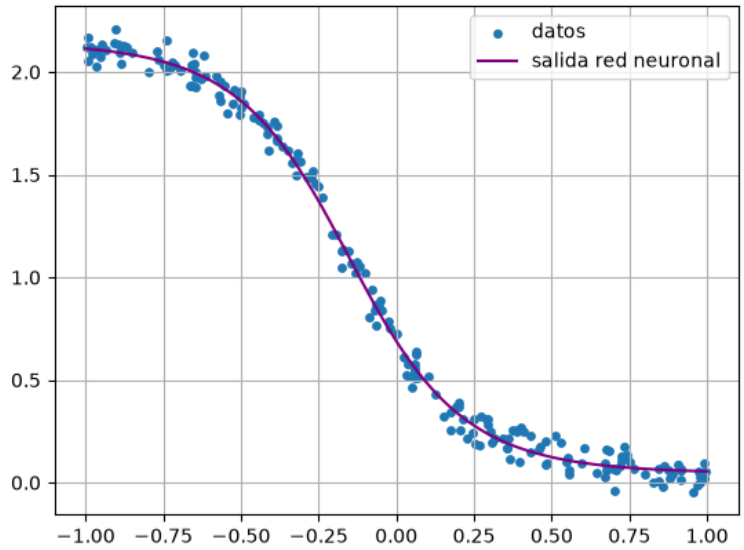
$$\hat{y}(x; \theta_{20.000}) = c + v\,\sigma\big(a_2\,\sigma(a_1 x + b_1) + b_2\big).$$

En el notebook guardamos los 100 valores de x en un arreglo y calculamos cada capa (z_1, h_1, z_2, h_2 y $\hat{y}$) sobre los 100 valores a la vez, obteniendo una salida $\hat{y}$ para cada x. Finalmente graficamos estos 100 puntos $(x, \hat{y})$ unidos como curva, junto a los datos de entrenamiento (x_i, y_i) como puntos

Valores encontrados.

- Capa oculta 1: $a_1 = -4.366758916139333, \quad b_1 = -0.7473648017493512$
- Capa oculta 2: $a_2 = 3.5558165161029365, \quad b_2 = -1.62743181581607$
- Capa de salida: $v = 2.960878308189766, \quad c = -0.43981266258598267$

con error $J(\theta_{20.000}) = 0.001373561381571473$ mucho menor que el error inicial $J(\theta_0) = 0.603522343354513$



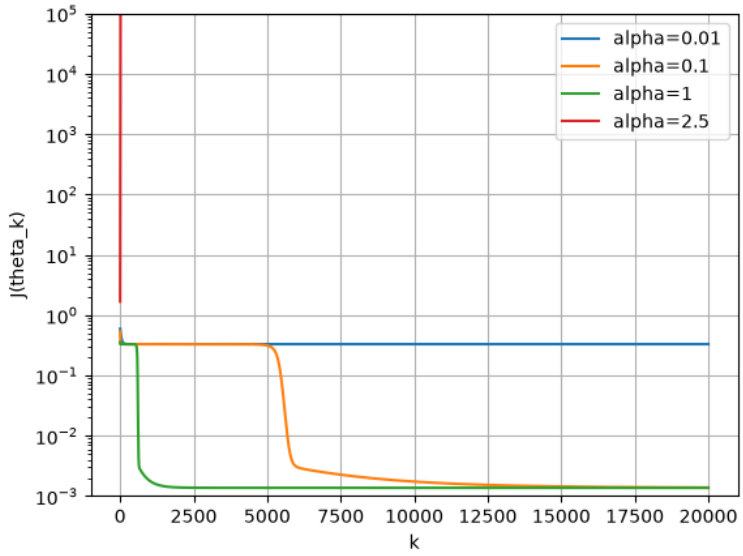
Inciso (f)i.

Repetimos el descenso del gradiente del inciso (d), partiendo del mismo θ_0 y por 20.000 iteraciones, pero ahora cambiando el valor de alpha

$$\theta_{k+1} = \theta_k - \alpha \nabla J(\theta_k), \qquad \alpha \in \{0.01;\ 0.1;\ 1;\ 2.5\}.$$

En el notebook, para cada α reiniciamos θ en θ_0, guardamos el error $J_k = J(\theta_k)$ de cada iteración en un arreglo e imprimimos su valor en las iteraciones 1, 500, 10.000 y 20.000. Luego graficamos los puntos (k, J_k) de los cuatro α juntos. Como tenemos un error grande y otros muy pequeños, para ver mejor, usamos escala logaritmica en el eje y de modo que las curvas no se ven planas

1. calculamos el gradiente con la función de (c), $g_k = \nabla J(\theta_k)$
2. actualizamos los parámetros, $\theta_{k+1} = \theta_k - \alpha\, g_k$
3. calculamos el error con los nuevos parámetros, $J(\theta_{k+1})$ para guardarlo en un arreglo



Conclusión. Como $\theta_{k+1} - \theta_k = -\alpha \nabla J(\theta_k)$, el paso α decide cuánto se mueve θ en cada iteración

- $\alpha = 0.01$: el error disminuye en un inicio, luego casi no cambia entre 10.000 y 20.000 el número es casi el mismo, entonces con un alfa muy pequeño no hay mucha variacion
- $\alpha = 0.1$: el inicio es similar al anterior, pero luego el cambio es más significativo y se nota un descenso evidente del error
- $\alpha = 1$: el error parte más bajo que en los anteriores y el resultado final es muy similar al de $\alpha = 0.1$
- $\alpha = 2.5$: las diferencias son mucho más significativas, pero no hay descenso, el error crece. Luego supera el mayor número representable, por lo que aparecen avisos de *overflow* y las operaciones entre infinitos dan nan. El método diverge: $J \to \infty$.

Además notamos que si α es muy pequeño, el error baja, pero muy poco en cada iteración y si α es muy grande, el error puede crecer en vez de bajar. El mejor alpha es $\alpha = 1$.

Inciso (f)ii.

Repetimos nuevamente el inciso (d) con $\alpha = 1$ y 20.000 iteraciones, pero partiendo de 10 inicializaciones al azar con en $[-1, 1]$ y otras 10 en $[-5, 5]$. En el notebook, para cada inicialización hicimos lo siguiente:

1. Elegimos $\theta_0 = (a_1, b_1, a_2, b_2, v, c)$ al azar con sus seis componentes en $[-1, 1]$, o en $[-5, 5]$
2. Pasamos el primer dato x_1 por las dos capas ocultas con θ_0,
$$t = z_2 = a_2\,\sigma(a_1 x_1 + b_1) + b_2, \qquad h_2 = \sigma(z_2)$$
3. **Derivada de la sigmoide en t.** Como por (a) $\sigma'(t) = \sigma(t)\big(1 - \sigma(t)\big)$ y $h_2 = \sigma(z_2)$, entonces $\sigma'(z_2) = h_2(1 - h_2)$ así obtenemos $\sigma'(z_2)$
4. **Entrenamiento.** Desde θ_0 repetimos 20.000 veces. Calculamos el gradiente con la función de (c) y actualizamos los parámetros
$$\theta_{k+1} = \theta_k - \nabla J(\theta_k).$$
Al terminar guardamos solo el error final, $J1_i = J(\theta_{20.000})$ para $[-1, 1]$ y $J5_i = J(\theta_{20.000})$ para $[-5, 5]$

Como el gradiente es un promedio sobre los 200 datos, repetimos el cálculo pasando todos los x_i y tomando el promedio $\frac{1}{N}\sum_{i=1}^{N}\sigma'(z_{2,i})$. Finalmente, para comparar ambos rangos, en el notebook calculamos el promedio y la mediana de los 10 errores finales de cada uno

$$\overline{J1} = \frac{1}{10}\sum_{i=1}^{10} J1_i, \qquad \overline{J5} = \frac{1}{10}\sum_{i=1}^{10} J5_i,$$

Conclusión.

- J final no siempre es el mismo, $J1$ y $J5$ son diferentes e incluso dentro de cada rango las inicializaciones no repiten. El promedio de $J5$ es 49 veces el de $J1$, aunque sus medianas son casi iguales. Como el promedio aumenta con unos pocos valores muy grandes y la mediana no, esto indica que la mayoría de las inicializaciones llegan a un error similar, pero en $[-5, 5]$ algunas quedan en un error mucho mayor.
- Recordando por (a) que $\sigma'(t)$ alcanza su máximo en $t = 0$ y se hace cada vez más chico con t lejos de 0. Con θ_0 en [-5,5] los parámetros son más grandes, por lo que los valores de $t = z_2$ tienden a quedar más lejos de 0 que en [-1,1]. Esto se observa en el notebook, donde en [-1,1] todos los t quedan cerca de 0, mientras que en $[-5, 5]$ varios quedan lejos de 0 y su $\sigma'(z_2)$ es mucho más pequeño. Como el gradiente se multiplica por $\sigma'(z_2)$, también queda muy pequeño y los parámetros cambian muy poco. Por lo tanto, mientras más lejos de 0 está t, más pequeño es $\sigma'(z_2)$ y más probable es que el entrenamiento quede en un error alto.
- El descenso del gradiente disminuye el error, pero no asegura el mínimo global, ya que no se llega a un único valor, como si cerca del mínimo J fuera una llanura plana. El gradiente es casi 0, entonces el método se detiene en cualquier zona plana, aunque el error ahí sea alto, por lo que el resultado depende de θ_0.

Inciso (g)i.

Cargamos el segundo archivo con los pares $(x_i, \tilde{y}_i)$ y el error es $J(\theta) = \frac{1}{2N}\sum_{i=1}^{N}\big(\hat{y}(x_i;\theta) - \tilde{y}_i\big)^2$

Entrenamiento. Partiendo del mismo θ_0 de (c), aplicamos el descenso del gradiente del inciso (d) por 20.000 iteraciones

$$\theta_{k+1} = \theta_k - \alpha\,\nabla J(\theta_k), \qquad \alpha = 1,$$

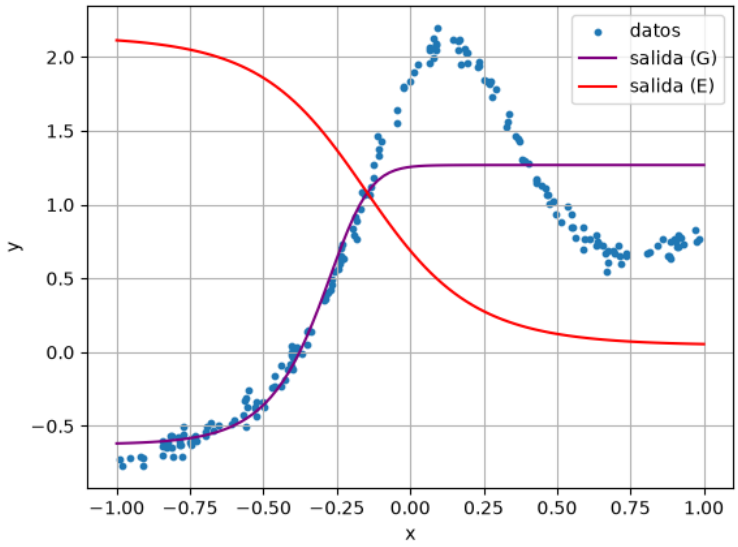
obteniendo los seis parámetros entrenados $\theta_{20.000} = (a_1, b_1, a_2, b_2, v, c)$, con los que el error bajó de

$$J(\theta_0) = 0.468164 \qquad \text{a} \qquad J(\theta_{20.000}) = 0.079292.$$

Salida de la red. Igual que en (e), tomamos 100 valores de x igualmente espaciados en $[-1, 1]$ y en cada uno calculamos la salida de la red capa por capa con los nuevos parámetros

$$\hat{y}(x;\theta_{20.000}) = c + v\,\sigma\big(a_2\,\sigma(a_1 x + b_1) + b_2\big).$$

Luego graficamos los datos nuevos $(x_i, \tilde{y}_i)$ junto a esta curva y a la curva obtenida en (e).



Conclusión. Notamos que al inicio tanto los datos como la curva suben, luego la curva se aplana mientras los datos siguen subiendo y dejan de coincidir. Después se vuelven a cruzar en un solo punto, pero los datos bajan y la curva sigue plana. Por eso la red no logra ajustar estos datos, solo se ajusta a una parte. Esto también se ve en el error final, $J(\theta_{20.000}) = 0.079292$, mucho mayor que el 0.001374 obtenido en (d).

Comparando con (e), la curva de (G) sube y la de (e) baja, y como una solo sube y la otra solo baja, se cruzan en un solo punto.

Inciso (g)ii.

Monotonía. Para cualquier $\theta \in \mathbb{R}^6$, por regla de la cadena $\frac{d\hat{y}}{dx} = v \cdot \sigma'(z_2) \cdot a_2 \cdot \sigma'(z_1) \cdot a_1$ Por (a), $\sigma' > 0$, entonces el signo de la derivada es el de $a_1 a_2 v$. Así la derivada nunca cambia de signo si $a_1 a_2 v > 0$, $\hat{y}$ siempre sube; si $a_1 a_2 v < 0$, siempre baja; y si $a_1 a_2 v = 0$, es constante. Por lo tanto $\hat{y}$ es monótona.

Cotas. Como $e^{-z_2} > 0$, se tiene $0 < h_2 = \frac{1}{1+e^{-z_2}} < 1$. En $\hat{y} = c + v\, h_2$, si h_2 fuera 0 tendríamos c y si fuera 1 tendríamos $c + v$, por lo que $\hat{y}$ siempre está entre c y $c + v$

$$c < \hat{y} < c + v \;\text{ si } v > 0, \qquad c + v < \hat{y} < c \;\text{ si } v < 0.$$

En el notebook. Para comprobarlo hicimos lo siguiente:

1. Tomamos 15 valores de θ al azar en $[-1, 1]$ y, para cada uno, 10 valores de x al azar en $[-1, 1]$.
2. En cada x calculamos la derivada por diferencias centradas

   $$\frac{d\hat{y}}{dx} = \frac{\hat{y}(x+h) - \hat{y}(x-h)}{2h} \qquad h = 10^{-5},$$

   y en cada θ las 10 derivadas tuvieron el mismo signo que $a_1 a_2 v$.
3. Para las cotas, si $\hat{y}$ está entre c y $c + v$, al restarle cada una, una resta da positiva y la otra negativa, por lo que revisamos con un booleano que $(\hat{y} - c)\big(\hat{y} - (c+v)\big) < 0$ que dio verdadero en todos los casos.
4. Como ejemplo, para el último θ ordenamos los x de menor a mayor y los $\hat{y}$ avanzaron en una sola dirección.

Conclusión. En el gráfico de la parte (i) los datos suben y luego bajan, es decir, cambian de dirección dentro de $[-1, 1]$. En cambio, para cualquier θ la salida de la red es monótona y queda entre c y $c + v$. Por eso la red logra seguir la parte donde los datos suben, pero cuando empiezan a bajar no puede devolverse y se queda plana. Como entrenar solo cambia el valor de θ, sin importar cuántas iteraciones se realicen, ni qué valor α o inicialización se use, la red no puede aproximar bien a $\tilde{f}$ en $[-1, 1]$.

- El descenso del gradiente disminuye el error, pero no asegura el mínimo global.