Tarea Computacional · IMT2220 Cálculo para Ciencia de Datos (2026-2)

Problema 1: Reconstrucción de una imagen

Grupo: 7

Integrantes:

- Agustín Pérez
- Cristóbal Robinson
- Vicente Pardo
- Sofía Solorza

Configuración

Librerias

In [1]:
```
# Se importan librerias permitidas para resolver el problema
import numpy as np
import matplotlib.pyplot as plt

# usamos esta libreria para guardar las imagenes generadas en el notebook
import os
```

Carga de datos

In [2]:
```
# Se usa la forma que se muestra en el enunciado
datos = np.load("datos_P1.npz")

matriz_a = datos["A"]
vector_b = datos["b"]
```

In [3]:
```
# Funcion para guardar las imagenes generadas en el notebook

# antes se crea la carpeta donde se guardaran las imagenes generadas en el notebook
os.makedirs("figuras", exist_ok=True)

def guardar_imagen(imagen, titulo, nombre_archivo):
    plt.figure(figsize=(6, 6))
    plt.imshow(imagen.reshape(64, 64), cmap="gray", vmin=0, vmax=1)
    plt.title(titulo)
    plt.axis("off")
    # Guardamos la imagen en la carpeta
```

```
    plt.savefig(os.path.join("figuras", nombre_archivo), bbox_inches="tight", dpi=2
    plt.close()
```

(a) Mínimos Cuadrados

El desarrollo está en el informe.

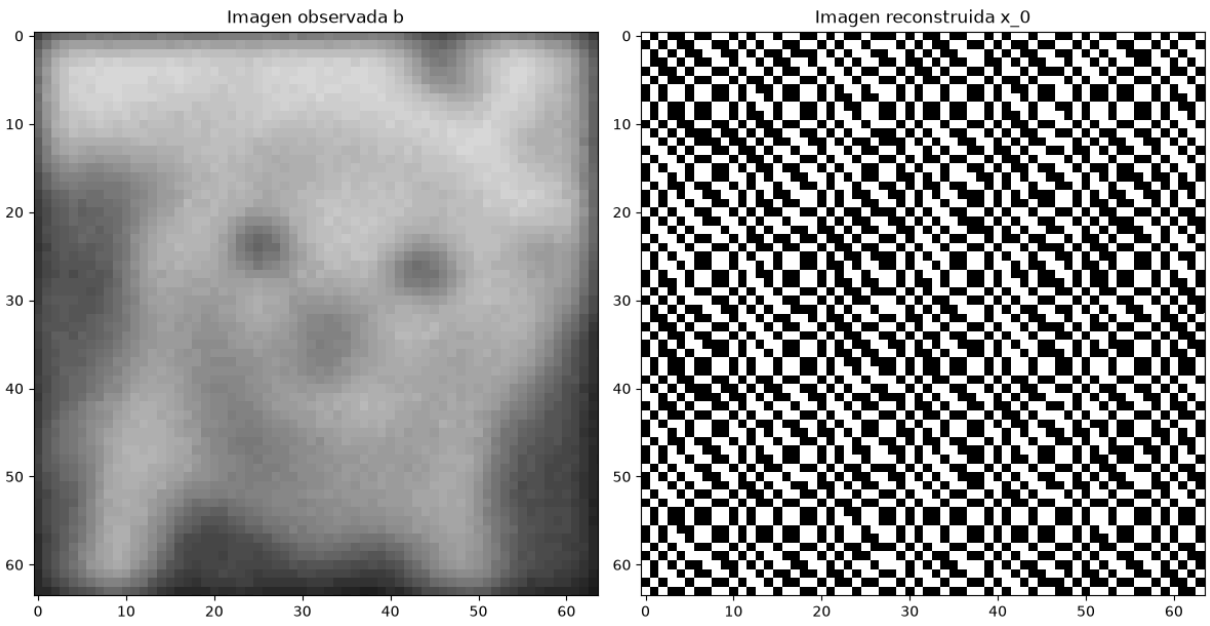
(b) Reconstrucción

b.i.- Implementación

In [4]:
```
# Calculamos x_0, para esto resolvemos el sistema lineal
# En el enunciado se menciona que se puede utilizar np.linalg.solve
x_0 = np.linalg.solve(matriz_a, vector_b)

# Comparamos la reconstrucción con la imagen observada
fig, ax = plt.subplots(1, 2, figsize=(12, 6))
ax[0].imshow(vector_b.reshape(64, 64), cmap="gray", vmin=0, vmax=1)
ax[0].set_title("Imagen observada b")
ax[1].imshow(x_0.reshape(64, 64), cmap="gray", vmin=0, vmax=1)
ax[1].set_title("Imagen reconstruida x_0")
plt.tight_layout()
plt.show()

# Guardamos cada figura por separado
guardar_imagen(vector_b, "Imagen observada b", "imagen_observada_b.png")
guardar_imagen(x_0, "Imagen reconstruida x_0", "imagen_reconstruida_x0.png")
```



Calculamos la norma, max y el residuo

In [5]:
```python
# norma euclidiana
norma_euclidiana_x0 = np.linalg.norm(x_0)

# maximo absoluto de x_0
max_x0 = np.max(np.abs(x_0))

# residuo, para este vamos a calcular la matriz A por x_0
# por lo que vi si se puede usar "@" para multiplicar matrices
residuo = np.linalg.norm(matriz_a @ x_0 - vector_b)
```

Revisamos los resultados

In [6]:
```python
print(f"Norma euclidiana de x_0: {norma_euclidiana_x0}")
print(f"Maximo absoluto de x_0: {max_x0}")
print(f"Residuo: {residuo}")
```

```
Norma euclidiana de x_0: 992626.416729
Maximo absoluto de x_0: 55257.75733986092
Residuo: 1.5111379587256674e-11
```

b.i.- Respuestas

¿x_0 se parece a b?

- No, mientras que b muestra la imagen algo borrosa pero entendible, en x_0 solo muestra los píxeles blancos y negros sin alguna forma reconocible. Esto ocurre porque sus valores estan fuera de $[0, 1]$ y al graficar con vmin = 0 y vmax = 1, el resto de la información se pierde

¿Se parece a una imagen?

- No, como se mencionó antes, solo se puede ver los píxeles sin forma, como ruido. Ademas, no podria ser interpretada como una imagen, ya que una imagen tiene píxeles en $[0, 1]$, y como la norma tiene que ser a lo mas $\sqrt{n} = 64$ y su maximo es a lo mas 1, mientras que $\|x_0\|_2 \approx 992626$ y $\max_i |x_{0,i}| \approx 55258$ valores mucho mayores a los esperados.

Residuo.

- $\|Ax_0 - b\|_2 \approx 1.5 \cdot 10^{-11}$, es decir, x_0 resuelve $Ax = b$ casi de forma exacta. Sin embargo, como $b = Ax^* + \eta$, al ajustar b exactamente x_0 también reproduce el ruido η . Por lo que un residuo pequeño no implica una buena reconstrucción.

b.ii.- Explicación

El desarrollo está en el informe. En resumen, el error de x_0 en cada dirección propia v_i proviene solo del ruido η y queda dividido por μ_i, por lo que aumenta mucho cuando μ_i es pequeño. Como 1858 de los 4096 valores propios son menores que 10^{-6} y el menor es

$\approx 2 \cdot 10^{-16}$, el error causado por el ruido se amplifica en casi la mitad de las direcciones. Por eso, aunque el ruido es pequeño ($\|\eta\|_2 \approx 0.64$), se obtiene $\|x_0\|_2 \approx 992626$, muy por encima de 64.

(c) Regularización de Tikhonov (método ridge)

c.iv.- Implementación

Primero creamos los elementos basicos

In [7]:
```python
# Calculamos la matriz A^tA
AtA = matriz_a.T @ matriz_a

# Calculamos el vector A^tb
Atb = matriz_a.T @ vector_b

# Y la matriz identidad
n = matriz_a.shape[0]
matriz_identidad = np.eye(n)
```

Calculo de las reconstrucciones

In [8]:
```python
# Creamos la matriz del sistema para cada lambda y resolvemos
# Usamos una lista lambda para guardar los valores de lambda que se van a probar
lista_lambda = [10**-3.5, 10**-2.5, 1]
lista_lambda_strings = ["10^-3.5", "10^-2.5", "1"] # para que el print sea mas ente

resultados = []
for valor_lambda, lambda_string in zip(lista_lambda, lista_lambda_strings):
    matriz_sistema = AtA + valor_lambda * matriz_identidad
    solucion = np.linalg.solve(matriz_sistema, Atb)

    # Calculamos la norma de x_lambda
    norma_x_lambda = np.linalg.norm(solucion)
    # y su residuo
    residuo_x_lambda = np.linalg.norm(matriz_a @ solucion - vector_b)

    # Mostramos los resultados
    print(f"Resultados para lambda = {lambda_string}:")
    print(f"Norma de x_lambda: {norma_x_lambda}")
    print(f"Residuo de x_lambda: {residuo_x_lambda} (delta: 0.64)") # Enunciado pia
    print()

    # y por ultimo guardamos la reconstrucción para mostrarla
    resultados.append(solucion)
```

```
Resultados para lambda = 10^-3.5:
Norma de x_lambda: 41.135990957686076
Residuo de x_lambda: 0.5545587811349489 (delta: 0.64)
```

```
Resultados para lambda = 10^-2.5:
Norma de x_lambda: 40.17481845801241
Residuo de x_lambda: 0.6125143500730488 (delta: 0.64)

Resultados para lambda = 1:
Norma de x_lambda: 19.3344726724977
Residuo de x_lambda: 19.975280603910214 (delta: 0.64)
```

Reconstrucción con regularización de Tikhonov

In [9]:

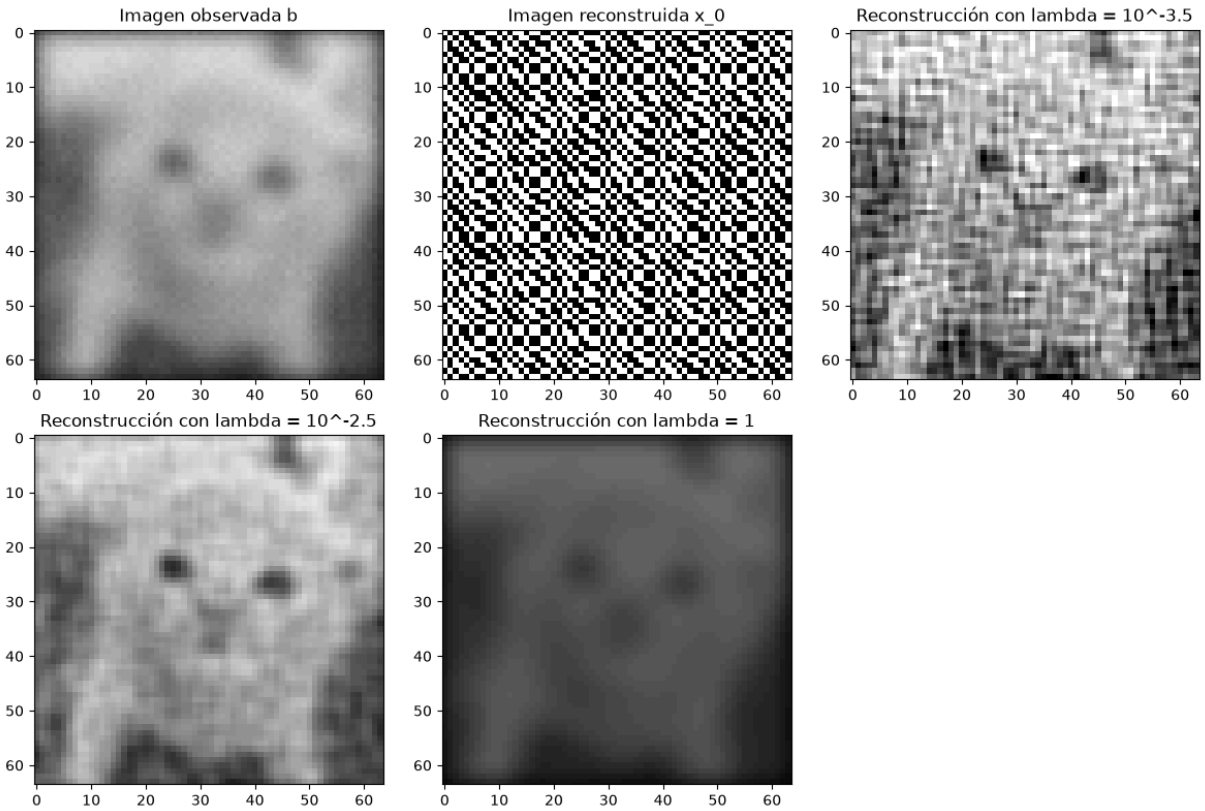
```python
fig, ax = plt.subplots(2, 3, figsize=(12, 8))
ax = ax.flatten()  # Aplanamos el arreglo de ejes para poder indexarlos facilmente

ax[0].imshow(vector_b.reshape(64, 64), cmap="gray", vmin=0, vmax=1)
ax[0].set_title("Imagen observada b")
ax[1].imshow(x_0.reshape(64, 64), cmap="gray", vmin=0, vmax=1)
ax[1].set_title("Imagen reconstruida x_0")

# Ahora mostramos las reconstrucciones para cada lambda
ax[2].imshow(resultados[0].reshape(64, 64), cmap="gray", vmin=0, vmax=1)
ax[2].set_title(f"Reconstrucción con lambda = {lista_lambda_strings[0]}")
ax[3].imshow(resultados[1].reshape(64, 64), cmap="gray", vmin=0, vmax=1)
ax[3].set_title(f"Reconstrucción con lambda = {lista_lambda_strings[1]}")
ax[4].imshow(resultados[2].reshape(64, 64), cmap="gray", vmin=0, vmax=1)
ax[4].set_title(f"Reconstrucción con lambda = {lista_lambda_strings[2]}")
ax[5].axis('off')  # Ocultamos el ultimo ya que no tiene imagen

plt.tight_layout()
plt.show()


# Ahora guardamos para cada una de las reconstrucciones con lambda
guardar_imagen(resultados[0], f"Reconstrucción con lambda = {lista_lambda_strings[0
guardar_imagen(resultados[1], f"Reconstrucción con lambda = {lista_lambda_strings[1
guardar_imagen(resultados[2], f"Reconstrucción con lambda = {lista_lambda_strings[2
```



c.iv.- Respuestas

Compare las reconstrucciones con x_0

- Las tres reconstrucciones tienen norma menor a 64 (≈ 41.1, 40.2 y 19.3), mientras que $\|x_0\|_2 \approx 992626$. Esto pasa porque, por (b) ii, en x_0 el aporte del ruido está acotado por $\|\eta\|_2/\sqrt{\mu_i}$, y como hay μ_i muy pequeños puede ser muy grande. En cambio, por (c) ii, en x_λ el aporte del ruido queda acotado por $\|\eta\|_2/(2\sqrt{\lambda})$, que no depende de μ_i, es decir, para un λ fijo es la misma cota en todas las direcciones v_i, incluso en las que tienen μ_i muy pequeño. Así el ruido tiene un límite que no puede superar, sin importar la dirección, y por eso se puede ver una imagen.

¿Cuál de los tres valores de λ entrega la mejor reconstrucción?

- $\lambda = 10^{-3.5}$. Se reconoce la imagen, pero con algunos patrones raros. Por (c) iii, como λ es pequeño, el límite del ruido $\|\eta\|_2/(2\sqrt{\lambda}) \approx 18$ es mayor, por lo que entra más ruido. Además, su residuo ≈ 0.55 es menor que $\delta = 0.64$, es decir, se ajusta a b más de lo que debería y también reproduce parte del ruido.

- $\lambda = 1$. La imagen se ve oscura y borrosa, ya que se pierde información de la imagen. Por (c) iii, como λ es grande, el factor $\mu_i/(\mu_i + \lambda)$ se acerca a 0 en las direcciones con $\mu_i \ll \lambda$, y como hay muchos μ_i pequeños, esas componentes de la imagen prácticamente desaparecen. El ruido se elimina, pero también parte de la imagen, por eso su norma es la menor (≈ 19.3) y su residuo ≈ 20 es mucho mayor que δ.

- La mejor reconstrucción es con $\lambda = 10^{-2.5}$, ya que es la que mejor se entiende y su residuo ≈ 0.61 es el más cercano a $\delta = 0.64$. Es decir, se ajusta a b solo hasta el nivel del ruido, equilibrando recuperar la imagen y controlar el ruido.

(d) Píxeles dañados

In [10]:
```
vector_b_def = datos["b_def"]

# Hacemos el mismo procedimiento que antes pero ahora con b_def
Atb_def = matriz_a.T @ vector_b_def

# El enunciado nos pide para 10^-2.5
matriz_sistema_def = AtA + (10**-2.5) * matriz_identidad
solucion_def = np.linalg.solve(matriz_sistema_def, Atb_def)

norma_def = np.linalg.norm(solucion_def)
residuo_def = np.linalg.norm(matriz_a @ solucion_def - vector_b_def)

print(f"Norma de x_lambda con b_def: {norma_def}")
print(f"Residuo de x_lambda con b_def: {residuo_def}")

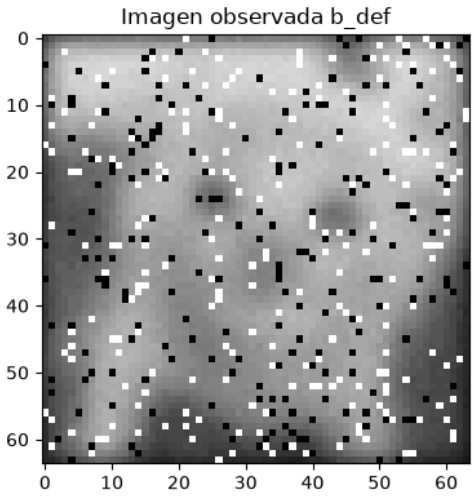
# Por ultimo mostramos la reconstrucción con b_def, comparamos con la imagen observ
fig, ax = plt.subplots(2, 2, figsize=(12, 8))

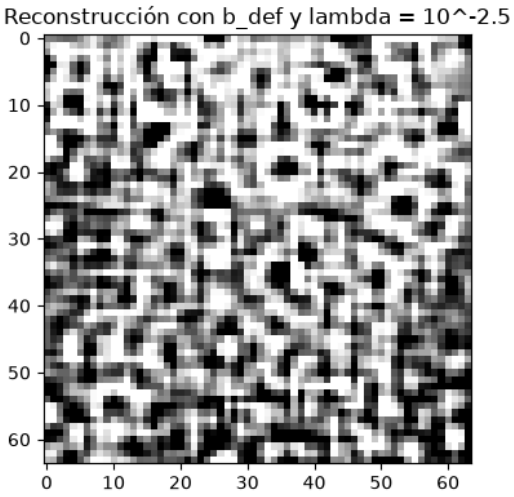
ax[0, 0].imshow(vector_b_def.reshape(64, 64), cmap="gray", vmin=0, vmax=1)
ax[0, 0].set_title("Imagen observada b_def")
ax[0, 1].imshow(solucion_def.reshape(64, 64), cmap="gray", vmin=0, vmax=1)
ax[0, 1].set_title("Reconstrucción con b_def y lambda = 10^-2.5")
ax[1, 0].imshow(vector_b.reshape(64, 64), cmap="gray", vmin=0, vmax=1)
ax[1, 0].set_title("Imagen observada b")
ax[1, 1].imshow(resultados[1].reshape(64, 64), cmap="gray", vmin=0, vmax=1)
ax[1, 1].set_title("Reconstrucción con b y lambda = 10^-2.5")

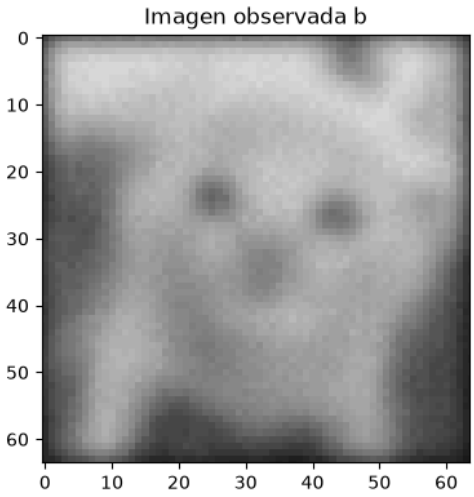
plt.tight_layout()
plt.show()

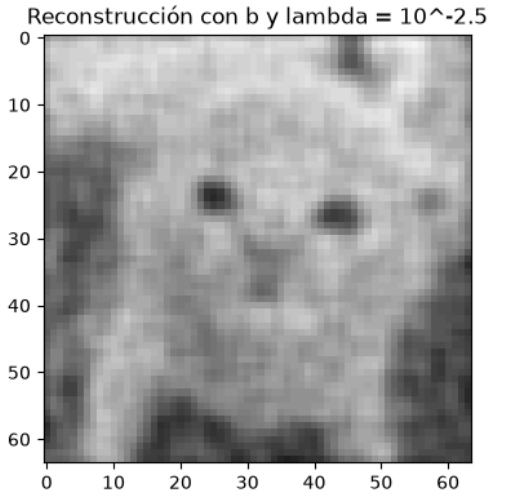
# Volvemos a guardar las imágenes generadas por separado
guardar_imagen(vector_b_def, "Imagen observada b_def", "imagen_observada_b_def.png"
guardar_imagen(solucion_def, "Reconstrucción con b_def y lambda = 10^-2.5", "recons
```

```
Norma de x_lambda con b_def: 48.6911168401266
Residuo de x_lambda con b_def: 10.084028267435565
```









d.- Explicación

El desarrollo está en el informe. Usando el mismo $\lambda = 10^{-2.5}$ que dio la mejor reconstrucción en c.iv, ahora la imagen no se reconoce y solo se observa un patrón desordenado de manchas blancas y negras. La norma ≈ 48.7 es parecida a la obtenida con $b \approx 40.2$, pero el residuo sube de ≈ 0.61 a ≈ 10.1, muy por encima de $\delta = 0.64$. Esto ocurre porque la reconstrucción intenta ajustarse también a las lecturas de los píxeles dañados, que no corresponden a ninguna imagen, y se deforma al hacerlo.

d.ii.- $||\tilde{b} - b||_2$

In [11]:
```
norma_diferencia_b = np.linalg.norm(vector_b_def - vector_b)
print(f"Resultado ||b_def - b||_2 : {norma_diferencia_b}")
```

```
Resultado ||b_def - b||_2 : 10.884961772516812
```

In [12]:
```
# Comparamos con delta = 0.64
print(f"||b_def - b||_2 / delta : {norma_diferencia_b / 0.64}")
```

```
||b_def - b||_2 / delta : 17.00775276955752
```

d.ii.- Explicación

El desarrollo está en el informe. Se obtiene $\|\tilde{b} - b\|_2 \approx 10.88$, unas 17 veces $\delta = 0.64$. Como el ruido de esta observación es $\tilde{\eta} = \eta + (\tilde{b} - b)$ y $\|\eta\|_2 \approx 0.64$ es pequeño, casi todo el ruido proviene de los píxeles dañados y se obtiene que $\|\tilde{\eta}\|_2$ esta entre 10.24 y 11.52, es decir, entre 16 y 18 veces δ.

d.iii.- Explicación

El desarrollo está en el informe. En resumen, usando (c) ii con $\tilde{\eta}$ en lugar de η, el aporte del ruido en cada dirección queda acotado por $\|\tilde{\eta}\|_2/(2\sqrt{\lambda})$, mientras que la parte recuperada de x^* no cambia.

- ¿Por qué fracasa? Como $\|\tilde{\eta}\|_2$ es entre 16 y 18 veces δ, con el mismo $\lambda = 10^{-2.5}$ el aporte del ruido puede ser hasta unas 17 veces mayor que con b. Por eso el ruido ahora es mayor que la parte de la imagen y la reconstrucción queda como un patrón de manchas.

- ¿Bastaría con aumentar λ? No. Para reducir el ruido unas 17 veces habría que aumentar λ unas $17^2 \approx 289$ veces, es decir, usar $\lambda \approx 1$. Pero en (c) iv se vio que con $\lambda = 1$ la imagen queda oscura y borrosa, por lo que al aumentar λ se elimina el ruido, pero también se pierde información de la imagen.

(Bonus)

Por la (d) i, el ruido de la observación con píxeles dañados es $\tilde{\eta} = \eta + (\tilde{b} - b)$, donde η es el ruido del sensor y $\tilde{b} - b$ es el aporte de los píxeles dañados. Como cerca del 10% de los píxeles están dañados, el vector $\tilde{b} - b$ debería ser distinto de cero solo en esas posiciones. Por lo tanto, usamos $\tilde{b} - b$ para identificar los píxeles dañados y construir w

In [13]:
```
# Comprobamos
diferencia_pixeles = vector_b_def - vector_b
total_pixeles = 0
for i in range(len(vector_b)):
    if diferencia_pixeles[i] != 0:
        total_pixeles += 1
print(f"Total de pixeles dañados: {total_pixeles}")
```

```
Total de pixeles dañados: 430
```

In [14]:
```
vector_w = (diferencia_pixeles == 0).astype(int)  # 0 si el pixel esta dañado, 1 si

print(np.sum(vector_w))  # Total de pixeles no dañados
```

```
3666
```

Proceso

Como W es diagonal,

$$(Ax - \tilde{b})^T W (Ax - \tilde{b}) = \sum_{p=1}^{n} w_p \big((Ax)_p - \tilde{b}_p\big)^2,$$

asi que los pixeles con $w = 0$ no aparecen en la suma y por lo tanto la reconstruccion no se ve afectada por ellos.

Siguiendo el mismo procedimiento de (a) i, con $r(x) = Ax - \tilde{b}$ y $q_W(u) = u^T W u$, se obtiene $Dq_W(u) = 2u^T W$ y por la regla de la cadena y $W^T = W$,

$$\nabla J_W(x) = 2A^T W (Ax - \tilde{b}) + 2\lambda x$$

Igualando a cero y reordenando, se obtiene

$$\left(A^T W A + \lambda I\right) x = A^T W \tilde{b},$$

y buscamos la solucion de este sistema porque minimiza $J_W(x)$, que seria la mejor imagen reconstruida sin los pixeles dañados.

In [15]:
```
matriz_w = np.diag(vector_w)
AtWA = matriz_a.T @ matriz_w @ matriz_a

# Usamos el valor de lambda que aparece en el enunciado para la d
matriz_sistema_bonus = AtWA + (10**-2.5) * matriz_identidad

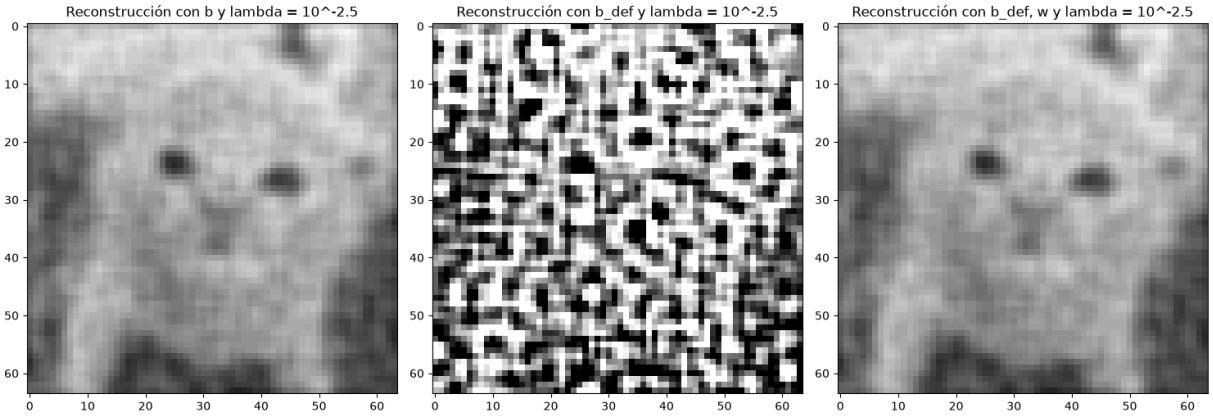
vector_b_bonus = matriz_a.T @ matriz_w @ vector_b_def

# Resolvemos el sistema
solucion_bonus = np.linalg.solve(matriz_sistema_bonus, vector_b_bonus)
```

In [16]:
```
# Graficamos y comparamos con la reconstrucción con b, b_def y lambda = 10^-2.5
fig, ax = plt.subplots(1, 3, figsize=(15, 5))

ax[0].imshow(resultados[1].reshape(64, 64), cmap="gray", vmin=0, vmax=1)
ax[0].set_title("Reconstrucción con b y lambda = 10^-2.5")
ax[1].imshow(solucion_def.reshape(64, 64), cmap="gray", vmin=0, vmax=1)
ax[1].set_title("Reconstrucción con b_def y lambda = 10^-2.5")
ax[2].imshow(solucion_bonus.reshape(64, 64), cmap="gray", vmin=0, vmax=1)
ax[2].set_title("Reconstrucción con b_def, w y lambda = 10^-2.5")
plt.tight_layout()
plt.show()

# Guardamos las imágenes generadas por separado
guardar_imagen(solucion_bonus, "Reconstrucción con b_def, w y lambda = 10^-2.5", "r
```



In [17]:
```
# Revisamos el residuo solo con los pixeles no dañados
residuo_bonus =np.linalg.norm(vector_w * (matriz_a @ solucion_bonus - vector_b_def)
print(f"Residuo: {residuo_bonus}")
```

```
Residuo: 0.5798508458103471
```

Bonus.- Conclusión

Al ignorar los píxeles dañados, la reconstrucción queda prácticamente igual a la obtenida a partir de b en (c) iv, mientras que sin w se obtiene un patrón desordenado de manchas blancas y negras. El residuo sobre los píxeles sanos es ≈ 0.58, cercano a $\delta = 0.64$, como en la mejor reconstrucción de (c) iv. Esto funciona porque, aunque se pierde cerca del 10% de las lecturas, cada píxel de la imagen influye en hasta 81 de ellas, así que aún le quedan aproximadamente unas 73 lecturas, información suficiente para reconstruirlo.